

单位代码：10610

学 号：2018223040106

四川大學

硕士研究生学位论文

(学术学位)

题目： 利用注意力惩罚项和强化学习

实现多标签情绪分类

培养单位： 计算机学院（软件学院）

作者姓名： 吴妍秀

指导教师： 于中华 副教授

学位类别： 工学硕士

学科专业： 软件工程

论文答辩时间：二〇二一年五月

学位授予时间：二〇二一年六月

Using Attention Penalty Term and Reinforcement Learning to Implement Multi-label Emotion Classification

**A dissertation submitted to Sichuan University
in partial fulfillment of the requirements
for the degree of**

Master of Science in Engineering

By

Wu Yanxiu

Supervisor: Prof. Yu Zhonghua

College of Computer, Sichuan University, Chengdu, China

May 2021



2018223040136

声 明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。据我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得四川大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

本学位论文成果是本人在四川大学读书期间在导师指导下取得的，论文成果归四川大学所有，特此声明。

作者签名：吴妍秀

导师签名：[Signature]
2024年 5月 26日

学位论文使用授权书

本学位论文作者完全了解四川大学有关保留、使用学位论文的规定，同意学校保留并向国家有关部门或相关机构送交论文的原件、复印件和电子版，允许论文被查阅和借阅。本人授权四川大学将本学位论文的全部或部分内容编入有关数据库进行信息技术服务，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文，并用于学术活动。

(涉密学位论文在解密后适用于本授权书)

作者签名：吴妍秀

导师签名：[Signature]
2024年 5月 26日



摘要

随着互联网的蓬勃发展,越来越多网民在社交平台上发表自己的言论,这些言论中通常包含大量的情绪信息,分析这些文本中蕴含的情绪可以为舆情分析等许多任务提供支持,拥有很高的应用价值。由于社交平台上用户发布的每一段文本通常包含多种情绪,且这些情绪间互相存在关联,捕捉这样的关联可以为准确识别文本中的情绪带来帮助,所以文本情绪分析应使用能够建模情绪关联性的多标签分类方法。

目前以序列到序列模型为基础的深度学习方法较早期工作更好地捕捉了情绪标签间的关联,然而这些方法解码端不同时刻的注意力关注相似位置的文本信息,倾向于生成语义相似的情绪标签,难以识别文本中语义相差较大的多种情绪。此外,这些方法采用的交叉熵损失函数依赖情绪标签的顺序,但现有数据集中情绪标签没有特定的标注顺序,导致了错误惩罚问题。

针对上述问题,本文工作如下:第一,由于现有方法难以识别文本中语义相差较大的多种情绪,本文提出了一种引入注意力惩罚项的多标签情绪分类方法,使用序列到序列模型建模标签间的高阶关联,通过注意力惩罚项捕捉情绪标签间的位置差异。实验结果表明,引入注意力惩罚项的方法相比现有最好的方法,在中、英文两个数据集上的分类效果均有提升。第二,针对标签顺序带来的错误惩罚问题,本文提出了一种基于强化学习的多标签情绪分类方法,利用延迟回报将序列生成过程转化为集合生成过程,将多个情绪标签看作集合。实验结果表明,引入强化学习的方法相比现有最新工作提出的方法,在中、英文两个数据集上的分类效果有进一步提升。

关键词: 多标签情绪分类; 序列到序列模型; 注意力机制; 强化学习



2018223040116

Abstract

With the vigorous development of the Internet, more and more netizens make their comments on social platforms, which contain a large amount of emotional information. The analysis of the emotions contained in the text can provide support for many tasks such as public opinion analysis, and has high application value. Since each text posted by users on social platforms usually contains a variety of emotions and these emotions are correlated with each other, capturing such correlation can help to accurately identify the emotions in the text, so text emotion analysis should use a multi-label classification method which can model correlation among emotion.

The current deep learning methods based on sequence-to-sequence model can better capture the correlation among emotion labels than earlier works. However, when multiple emotions co-exist in the text, decoder of these methods paying attention to the text information in similar position at different times, then tends to generate semantically similar emotion labels, makes it difficult to identify various emotions with large semantic differences in the text. In addition, the cross-entropy loss function adopted by these methods depends on the order of emotion labels, but the existing emotion labels in the datasets have no specific order of labeling, which leads to the problem of wrong penalty.

In view of the above problems, this paper works as follows: Firstly, since existing methods are difficult to identify multiple emotions with large semantic differences in text, this paper proposes a multi-label emotion classification method with attention penalty term. The sequence-to-sequence model is used to model the high-order correlation among labels, and the position difference among the emotion labels is captured by the attention penalty term. The experimental results show that, compared with the best existing methods, the method of introducing attention penalty term improves the classification performance on both Chinese and English datasets. Secondly, in order to solve the problem of wrong penalty caused by label order, this paper proposes a multi-label emotion classification method based on reinforcement learning, which transforms the sequence generation process into the set generation process by using the delayed reward so that multiple emotion labels can be regarded as a set. The experimental results show that, compared with the method proposed by the existing latest work, the method with reinforcement learning has a further improvement in the classification performance on Chinese and English datasets.



2018223040116

Key words: multi-label emotion classification; sequence to sequence model; attention mechanism; reinforcement learning



目 录

摘 要.....	I
Abstract.....	III
目 录.....	V
图表目录.....	VII
第 1 章 绪论.....	1
1.1 选题背景及意义.....	1
1.2 研究现状.....	2
1.3 本文主要工作.....	3
1.4 本文组织结构.....	4
第 2 章 相关工作.....	7
2.1 多标签分类任务.....	7
2.2 情绪分类任务.....	9
2.2.1 情绪多分类任务.....	9
2.2.2 多标签情绪分类任务.....	11
2.3 现有工作的问题.....	13
2.4 本章小结.....	14
第 3 章 引入注意力惩罚项的多标签情绪分类方法.....	15
3.1 多标签情绪分类任务特点.....	15
3.2 模型的提出及思想.....	16
3.3 引入注意力惩罚项的序列到序列模型.....	17
3.3.1 词嵌入模块.....	18
3.3.2 编码模块.....	18
3.3.3 注意力模块.....	20
3.3.4 解码模块.....	21
3.3.5 引入注意力惩罚项的损失函数.....	22
3.4 实验设计与分析.....	22
3.4.1 实验环境.....	22
3.4.2 实验数据.....	23
3.4.3 文本预处理.....	24



2018223040136

3.4.4 评价指标.....	25
3.4.5 实验设置.....	26
3.4.6 实验结果及分析.....	27
3.5 本章小结.....	30
第4章 基于强化学习的多标签情绪分类方法.....	31
4.1 模型的提出及思想.....	31
4.2 强化学习方法.....	32
4.2.1 强化学习.....	32
4.2.2 策略梯度.....	33
4.3 基于强化学习的序列到集合模型.....	33
4.4 实验设计与分析.....	35
4.4.1 实验环境.....	35
4.4.2 实验数据.....	35
4.4.3 评价指标.....	35
4.4.4 实验设置.....	36
4.4.5 实验结果及分析.....	36
4.5 本章小结.....	39
第5章 总结与展望.....	41
5.1 工作总结.....	41
5.2 研究展望.....	42
参考文献.....	43
攻读学位期间取得的研究成果.....	47
致 谢.....	49



图表目录

图 2.1	多标签分类方法概括.....	7
图 2.2	序列到序列模型解决多标签文本分类.....	8
图 2.3	情绪分类研究现状概括.....	9
图 2.4	潜在情绪记忆网络分类器结构图.....	13
图 3.1	Plutchik 八类情绪轮图.....	15
图 3.2	序列到序列模型结构图.....	16
图 3.3	引入注意力惩罚项的多标签情绪分类模型框架.....	17
图 3.4	LSTM 结构图.....	19
图 3.5	Bi-LSTM 结构图.....	19
图 3.6	注意力模块.....	20
图 3.7	解码模块.....	21
图 3.8	Ren-CECps 数据集样图.....	23
图 3.9	数据集情绪语义距离对比图.....	24
图 3.10	实验结果对比图.....	28
图 3.11	SemEval-2018 数据集误分类情况.....	30
图 4.1	强化学习过程示意图.....	32
图 4.2	Self-critical 结构图.....	34
图 4.3	实验结果对比图.....	38
表 1.1	文本情绪标签对照.....	3
表 3.1	情绪标签数量分布.....	23
表 3.2	数据集划分.....	24
表 3.3	混淆矩阵.....	25
表 3.4	超参数设置.....	27
表 3.5	Ren-CECps 数据集的实验结果对比.....	28
表 3.6	SemEval-2018 数据集的实验结果对比.....	28
表 3.7	SemEval-2018 数据集“本章方法-AttnDiff”误分类样例.....	29
表 4.1	Ren-CECps 训练集标签分布情况.....	35
表 4.2	SemEval-2018 训练集标签分布情况.....	35
表 4.3	超参数设置.....	36
表 4.4	Ren-CECps 数据集的实验结果对比.....	37



2018223040136

表 4.5	SemEval-2018 数据集的实验结果对比.....	37
表 4.6	Ren-CECps 数据集针对排序和强化学习的消融实验结果.....	38
表 4.7	SemEval-2018 数据集针对排序和强化学习的消融实验结果.....	39



第1章 绪论

本章深入分析了多标签情绪分类任务的背景及意义，简述了该任务的研究现状，尽管目前已有一些研究者提出了相关的解决方法，但是应用于该任务的模型与算法仍有不足，分类效果仍待提升，从而引出了对本文主要工作的简述，即从两个不同角度提出多标签情绪分类方法的改进方案，最后说明了全文的组织结构。

1.1 选题背景及意义

随着互联网技术和普及程度的日益提高，社交媒体得到快速发展。据中国互联网络信息中心（CNNIC）所发布的第47次《中国互联网络发展状况统计报告》^[1]，截至2020年12月，我国网民数量高达9.89亿，互联网普及率达70.4%。手机网民数量达9.86亿，网民使用移动设备上网的比例占99.7%，手机为日常上网带来极大的便利。网络新闻用户数量达7.43亿，占网民整体的75.1%。博客等平台也被视为新的网络新闻媒体，越来越多用户在博客、微博、推特等线上社交平台获取最新消息并发表自己的言论，这些言论中通常包括对某一事件或日常生活的观点以及情绪等大量信息。

自然语言处理（Natural Language Processing, NLP）是人工智能领域的重要分支，旨在让计算机理解人类的自然语言。分析社交媒体文本中的情绪信息可以为舆情分析^[2]（Public Opinion Analysis）、个性化推荐^[3]（Personalized Recommendation）、股票预测^[4]（Stock Forecasting）和心理干预^[5]（Psychological Intervention）等相关NLP任务提供支持，拥有很高的价值，应用前景较好，如何挖掘与分析网络用户生成文本中的情绪信息成为NLP领域重要的研究方向之一。

早期的情绪分析工作曾关注过情感极性分析^[6]（Sentiment Analysis）或观点挖掘^[7]（Opinion Mining）等粗粒度的分类任务，随着研究者的不断探索，更细粒度的情绪分类（Emotion Classification）成为情绪分析的主要子课题。情绪是外界事物所引起的爱、憎、愉快、不愉快、惧怕等心理状态，在心理学研究中存在多种分类方式：如Ekman^[8]将基础情绪划分为喜悦、悲伤、愤怒、恐惧、厌恶、惊讶这六类，在2007年SemEval竞赛情感文本分类任务^[9]中，1250条新闻标题使用了这种情绪分类体系进行标注。除此之外，Frijda^[10]定义了六种基本情绪：欲望、快乐、兴趣、惊奇、怀疑、悲伤；Poltchik^[11]提出了八种基础情绪的类别，分别是：赞同、愤怒、期待、厌恶、喜悦、恐惧、悲伤、惊讶。虽然不同研究者定义的情绪类别各有不同，但由此可见，情绪分类是心理学、社会学等学科经久不衰的研究内容，情绪的自动识别可以为这些学科的研究提供新的解决方法。



用于分类任务的一般算法，如支持向量机（Support Vector Machine, SVM）、决策树（Decision Tree）等机器学习方法或神经网络方法分类时使用的 Softmax 函数只能获取单个标签，因此早期的部分研究工作仅关注一个文本样例对应单个情绪标签的多分类任务。然而人类的情绪具有复杂性，每段用户生成的文本可能表达多种情绪，将情绪分类问题视为多标签分类问题更符合人的认知习惯。多标签情绪分类任务旨在将一个或多个情绪标签自动分配给语料库中的每条文本样例，即对文本发布者的多种情绪进行自动识别。识别文本中的多种情绪较一种情绪而言难度更高，并且属于同一段文本的多种情绪一般具有相关性，捕捉标签间关联使多标签情绪分类任务成为一项具有挑战的任务。

综上所述，无论是在实用性还是在挑战性的层面，多标签情绪分类都是一项值得研究的任务。

1.2 研究现状

根据对相关工作的分析与总结，近期研究倾向于使用机器学习或深度学习方法，机器学习方法包括有监督学习（Supervised Learning）和无监督学习（Unsupervised Learning），可以自动分析文本训练数据，并推导出一个函数用来映射新的样例；深度学习方法主要包括神经网络方法，如长短时记忆网络^[12]（Long Short Term Memory, LSTM）等，在最新的研究工作中占据主流。

情绪分类被部分研究者视为单标签的多分类问题，即每段文本仅拥有一种情绪标签，虽然简化了解决方法，但这类研究未考虑人类的情绪具有复杂性，即一段文本中可能包含多种情绪的情况。随着研究人员对情绪分类任务的进一步分析，以及多标签情绪分类数据集的构建与公开，情绪分类主要被看作成多标签分类任务。

用于解决多标签分类任务的一阶（First Order）方法采用逐个处理标签的方式，如传统的二元关联^[13]（Binary Relevance, BR），该方法将多标签分类问题转化为多个相互独立的二分类问题，一个标签使用一个分类模型。虽然此类方法具有简单高效的优点，但是忽视了共现情绪标签之间存在的关联。

用于解决该任务的二阶（Second Order）方法仅考虑了成对的两个标签之间的相关性，如校准标签排序^[14,45]（Calibrated Label Ranking, CLR）方法针对相关标签和不相关标签排序，或通过特定约束项引入标签对的相关性^[15]。此类方法能捕捉一定程度的标签关联，比一阶方法具有更好的性能，但是在社交平台上发布的文本中，情绪标签之间的关联性并不仅存在于二者之间。

用于解决该任务的高阶（High Order）方法可以考虑多个标签间的关联，一般使用序列或集合的方式实现关联性的捕捉，如分类器链^[16]（Classifier Chains, CC）将前序标签的影响施加到后序标签，或标签幂集^[17]（Label Powerset, LP）通过集合的方式建立标签关联。此类方法相较一阶和二阶方法可以更好地建模情绪标签间的关联，但是高



阶的机器学习方法存在计算要求高、扩展性弱的问题。神经网络的优势可以很好地解决上述问题，现有研究表明，可以通过序列到序列（Sequence to Sequence, Seq2Seq）模型^[18]解码端或序列二分类器^[51]的序列结构捕捉多个标签之间的影响，但此类方法不能很好捕捉文本中不同位置出现的情绪信息，并且标签的顺序会影响分类效果。

本文将在第二章中详细介绍本节简述方法的技术路线及优缺点。

1.3 本文主要工作

本文研究的内容为多标签情绪分类任务，即输入一段文本，输出这段文本对应的一个或多个情绪标签。如表 1.1 所示，每条用户发布的博客句子中蕴含一种或多种情绪，例如“感受着小手……”这一文本，该任务的目标为自动识别出其对应的三个情绪标签“anxiety, love, joy”。

表 1.1 文本情绪标签对照

Table 1.1 Map of text and emotion labels

博客句子	情绪标签
感受着小手的温度，享受着这份她对我的依恋，生怕动一下会让她的离我而去。	anxiety, love, joy
连余秋雨都将自己的大师头衔当笑话，旁人又何必呢？	anger
唉，冷漠啊，多一事不如少一事啊。	anxiety, sorrow, hate

假设 $X = R_d$ 为 d 维的样本空间， $Y = \{y_1, y_2, \dots, y_q\}$ 为存在 q 个情绪标签的标签空间，该任务可以定义为：从数据集中学习由文本到情绪标签的函数映射 $h: X \rightarrow 2^Y$ 。

本文首先阐述了多标签情绪分类的背景意义，总结和分析了多标签情绪分类任务的相关工作，该任务通常可以被转化为多个二分类任务或多分类任务解决，现有主流的深度学习方法一般先对输入文本进行词嵌入，建模获取文本的特征表达，再将其输入分类器获得最后的分类结果。本文使用基于深度学习的方法，根据多标签分类任务的特点及情绪标签相关的特征，利用注意力惩罚项与强化学习解决现有工作存在的问题。最后设置了一系列对比实验，相比现有最新工作，在 Ren-CECps 中文博客数据集^[19]及 SemEval-2018 英文推特数据集^[20]上，多项评价指标获得了较好的实验结果，验证了本文提出方法的有效性。

具体而言，本文的主要工作为以下几点：

(1) 针对现有方法对文本中语义相差较大的多种情绪识别效果差的问题，提出了引入注意力惩罚项的多标签情绪分类方法。



本文工作将多标签情绪分类问题转化为序列到序列建模的情绪标签生成问题,通过解码端的序列结构捕捉多个标签之间的关联性。多种语义差别较大的情绪在文本中共现时,不同情绪通常出现在不同的位置,对应表达大多间隔较远。然而现有工作由于一段文本通常对应多个相似的情绪,解码端不同时刻的注意力捕捉位置较为相似,丢失了文本其他部分的语义信息,难以识别差别较大的多个情绪标签。因此,本文引入注意力惩罚项,扩大注意力分布的差异性,避免模型仅生成相似的情绪标签。此部分工作的详细内容见第三章。

(2) 针对序列到序列模型需要情绪标签顺序导致的错误惩罚问题,提出了基于强化学习的多标签情绪分类方法。

在现有转化多标签分类问题为序列生成问题的方法中,由于现有多标签情绪分类数据集没有特定的标注顺序,通常需要启发式方法对情绪标签重排序。研究者多使用数据集中情绪标签的出现频率从高到低进行排序,然而这一排序方式仍不能保证成功获取标签的最优顺序。模型训练过程中可能存在真实标签与预测标签集合相同但顺序不同的情况,计算交叉熵损失会导致错误惩罚问题。现有避免该方法的方法均将模型解码端设置为固定顺序的二分类器,但固定序列存在标签间不同相对位置关系带来的依赖强度不统一的问题。将标签看作无序集合可以解决现有工作的不足,因此,本文将通过强化学习方法用回报的期望值代替一般的损失函数将该任务转化为标签集合生成任务,此部分工作的详细内容见第四章。

(3) 模型有效性的验证。

为验证本文提出的两个模型的有效性,本文在中文 Ren-CECps 数据集及英文 SemEval-2018 数据集上设计与现有工作的对比实验及消融实验。第一部分工作引入注意力惩罚项,相比于现有解决多标签情绪分类问题的最新工作,中文数据集的 macro-F1 值和 micro-F1 值分别提升了 0.6% 和 6.4%, 汉明损失降低了 1%, 英文数据集的 micro-F1 值提升了 0.6%, 汉明损失降低了 0.4%; 第二部分工作引入强化学习,相比于现有的最新工作,中文数据集的 macro-F1 值和 micro-F1 值分别提升了 5% 和 6.8%, 中文数据集的 macro-F1 值和 micro-F1 值分别提升了 0.5% 和 0.8%, 汉明损失降低了 0.4%。此部分的详细内容见 3.3.6 节与 4.4.5 节。

1.4 本文组织结构

本文一共分为五个章节,各部分的具体内容安排如下:

第一章: 绪论。本章主要介绍了多标签情绪分类任务这一课题的选题背景及意义,将该任务当前的相关工作进行了简单的归纳,简要分析了该任务的国内外研究现状,然后简略阐述了本文的主要工作,最后说明了本文的组织结构。

第二章: 相关工作。本章详细介绍了此课题的国内外研究现状,对其进行了总结归



纳，并分析了现有工作的不足，针对性地提出本文的两个改进点。

第三章：提出了引入注意力惩罚项的多标签情绪分类方法。本章详细阐述了任务特点，分析了现有方法的不足即引入注意力惩罚项这一改进的出发点，详细介绍了模型的整体框架和每个模块，最后为证明该方法的效果详细进行了实验工作，并且分析了实验结果。

第四章：提出了引入强化学习的多标签情绪分类方法。本章详细阐述了现有方法的不足及引入强化学习方法这一改进的出发点，介绍了强化学习的相关知识，详细介绍了模型中强化学习的各大要素及回报设计，最后为证明该方法的效果详细进行了实验工作，并且分析了实验结果。

第五章：总结与展望。本章对本文的工作进行了细致的总结，同时也分析了本文工作的不足，并对下一步工作的内容进行了展望。



2018223040136



第2章 相关工作

网络平台上用户生成的文本日益增多,针对这些文本进行的情绪分析工作具有很高的研究价值。多标签情绪分类任务作为情绪分析的主要形式受到了学术界和业界的广泛关注,该任务可以看作解决多标签分类问题。因此,本章将从多标签分类任务和情绪分类任务两个维度介绍相关工作。

本章在情绪分类任务的介绍中,首先简要回顾了单标签情绪分类任务,然后详细介绍并分析了近年多标签情绪分类任务的研究工作,发现了现有工作的不足之处,从而提出本文的两个改进方向。

2.1 多标签分类任务

多标签分类任务大多通过问题转化或改进算法的方式解决,问题转化的方式即转化多标签任务为其他常见的分类任务,改进算法的方式即改进现有的机器学习技术处理多标签数据。

如图 2.1 所示,问题转化的方法包括前文所提及的 BR、CLR、CC、LP 及对 LP 方法复杂度进行改进的随机 K 标签集 (Random K-Labelsets) 等;改进算法的方法包括多标签 K 近邻^[21](Multi-Label K Nearest Neighbor, MLKNN),多标签决策树^[22](Multi-Label Decision Tree, ML-DT), 排序支持向量机^[23] (Ranking Support Vector Machine, Rank-SVM) 等。

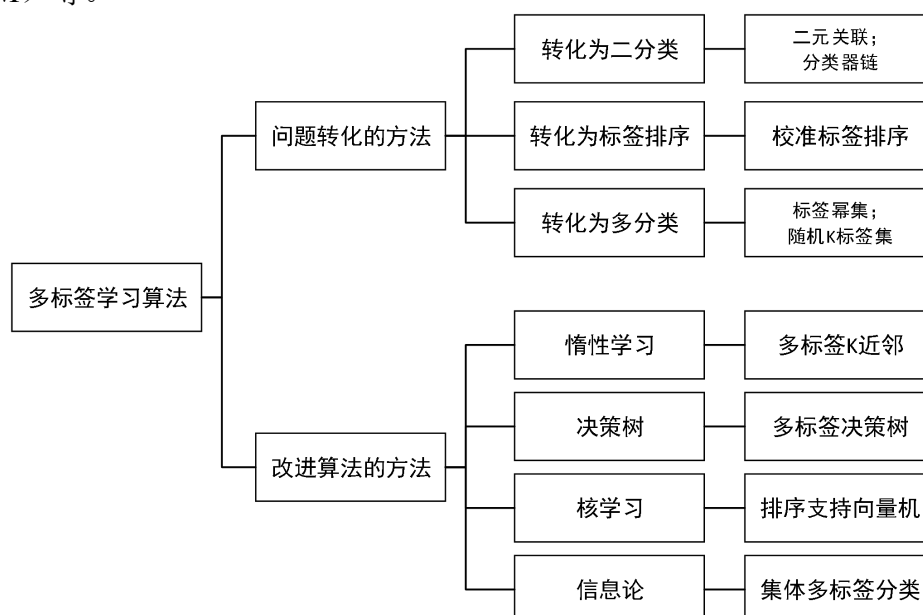


图 2.1 多标签分类方法概括

Figure2.1 Current status of multi-label classification methods

BR 方法将多标签分类问题转化为等同于标签类别数的 q 个互相独立的二分类问题，每个二分类任务对应一个可能的标签；MLKNN 算法通过改进 K 近邻算法处理多标签数据，根据邻居节点的标签信息利用最大后验进行预测。上述两种方法均为一阶方法，独立预测每个标签，忽略了标签的共现关系，未考虑标签之间的关联性，造成信息丢失，降低了分类效果。

排序-SVM 与 CLR 都是基于排序的方法，排序-SVM 算法采用最大间隔来处理多标签数据，对 q 个线性分类器进行优化，最小化排序损失，并利用核函数解决非线性情况；CLR 方法将多标签分类问题转化为标签排序问题，为每对标签构建二分类器，共计构建 $q(q-1)/2$ 个二分类器，使用自主学习的伪标签作为阈值分隔相关标签与不相关标签得到最后的分类结果。上述两种方法均为二阶方法，只考虑了两个标签之间的共现相关性，未考虑文本中的标签关联不止存在于二者之间。

CC 方法将多标签分类问题转化为链式的多个二分类问题，链中前一个分类器的分类结果将输入后续的分类器中；LP 方法将该问题转化为多分类问题，每个可能的标签集合被视为一个单独的标签。上述两种方法均为高阶方法，可以考虑标签之间的关联，但 CC 方法在训练过程中使用 Teacher-forcing（序列学习训练阶段的常用方法，即分类器的输入为前一个分类器的标注标签，而非前一个分类器的实际预测标签，该方法一般用于加快模型的收敛速度）会导致预测阶段的暴露偏差；LP 方法这一转化问题的方式，使标签数量级增长至 2^q ，呈幂级增长导致计算困难，扩展性弱。




图 2.2 序列到序列模型解决多标签文本分类^[18]

Figure 2.2 Sequence to sequence model solving multi-label text classification

神经网络具有自主学习特征，并行计算的优点，通过序列结构可以捕捉标签间高阶关联并避免机器学习方法的人工选择特征的缺陷。如图 2.2 所示，在文本主题分类方法的研究中，Yang 等人^[18]将多标签分类任务转化为标签序列生成任务，首次使用序列到序列模型解决多标签分类问题，首先在解码端使用双向 LSTM^[12]对文本进行编码，通过

注意力机制捕捉文本中对主题分类贡献更大的部分，最后在解码端使用多层 LSTM 对中间向量进行解码，顺序生成标签，并通过 mask 硬约束避免重复标签的出现。

然而传统的多标签文本分类语料多为新闻或百科等规范长文本，多标签情绪分类任务的文本多为网络平台上不规范的短文本，并且情绪之间的关联程度也与文本主题或内容标签间的关联程度不同，这些特殊性质意味着不能直接将多标签文本分类的模型用于多标签情绪分类任务，这也给该任务带来了新的挑战。

2.2 情绪分类任务

情绪分类的研究现状如图 2.3 所示，早期的情绪分类研究主要着眼于一条文本样例仅对应单个情绪标签的多分类任务，采用的方法可大致分为三类：基于词典或规则的方法，机器学习方法，深度学习方法。近年来，由于研究者对该任务的进一步分析，以及相关数据集的构建与公开，多标签情绪分类任务成为了主流，该任务的研究工作同样可以使用上述三类方法划分，但由于该任务的特殊性，依照 Zhang 等人^[24]在多标签分类方法综述中的分类方式，根据标签之间关联的捕捉程度分为一阶方法，二阶方法，高阶方法更为合适。

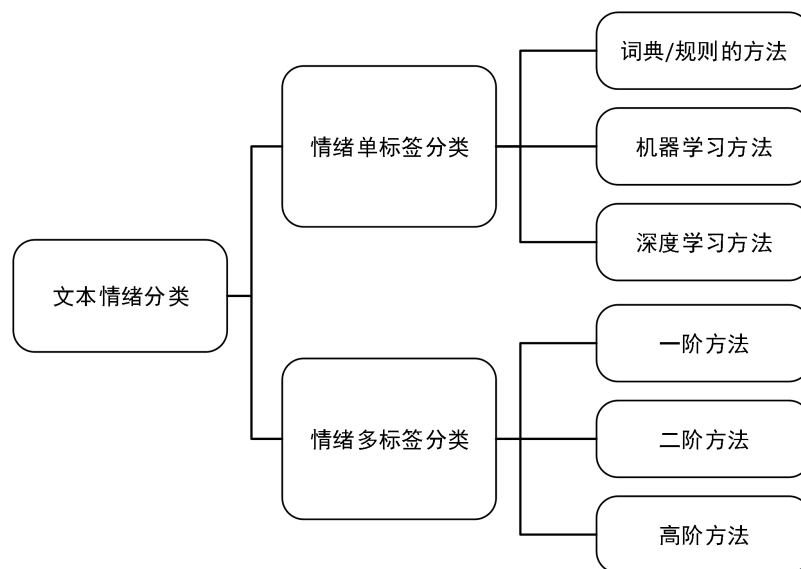


图 2.3 情绪分类研究现状概括

Figure2.3 Current status of the emotion classification research

2.2.1 情绪多分类任务

由于最初对情绪分类任务的分析存在不足，部分研究工作仅能解决单标签的多分类问题，即一段文本中仅包含一种情绪。早期的情绪分类研究采用基于词典匹配的方法，需要使用人工标注的情绪词典资源，将词典中的词与文本分词（Word Segmentation）处理后得到的词进行关键字的匹配，计算文本的情绪得分，现有词典包括加拿大国家研究



委员会标注的 NRC 词语情绪词典^[25]等；Strapparava 等人^[26]利用 WordNet-Affect^[27]词典检测新闻标题中情绪词的出现频率。由于微博等社交平台上用户生成的文本具有特殊性，较为口语化且包含许多表情符号，Shen^[28]等人通过构建态度词典、权重词典、否定词典及程度词典等一系列词典计算每条微博的情绪指数。然而微博文本中的网络词汇层出不穷且更新换代很快，人工构造词典不仅费时费力、覆盖率不够理想，并且无法探测新词。

基于模板和规则的方法需要专家通过分析数据集制定一系列规则，总结出对情绪分类任务有效的文本词性特征及语法特征，然后系统性构建相应的规则以解决情绪分类问题。Balahur 等人^[29]构建了触发情绪的常识库 EmotiNet，通过记录触发情绪的情景，从而对没有明确情绪词汇出现的文本进行自动检测。此类方法虽然易于理解，但是高度依赖语种和语言风格，如中英文文本存在不同的语法结构，新闻及推特文本存在不同的语言表达方式，针对不同的文本需要重新制定不同的规则，所以基于规则的方法不具有普适性，难以被复用。

与基于词典或规则的方法相比，机器学习方法无须标注大量的词或确定大量的规则，只需要人工确定任务相关的特征，如词性、语法结构等。在使用有监督方法的工作中，Roberts 等人^[30]使用七个二分类 SVM 检测七种情绪；Balabantaray 等人^[31]提取了文本的语法，语义及上下文特征，包括一元词、二元词、词性标注、Word-Net^[32]、表情符号等，训练带有核函数的多分类 SVM 作为分类器；Suttles 等人^[33]根据 Plutchick 定义的八种两两对立的基本情绪对情绪进行分类，将多类情绪分类问题视为四对对立情绪的二分类问题；Quan 等人^[34]使用潜在的主题变量（Latent Subject Variables）预测读者对于新闻的情绪投票，使用皮尔森相关系数（Pearson Correlation Coefficient）度量的情绪相关性作为约束项。在使用无监督方法的工作中，Agrawal 等人^[35]提出了一种无监督的基于上下文的句子级情绪检测方法，该方法不依赖于情感词典，且不需要固定具体的类别数量。但机器学习方法在人工构造文本特征时，通常要求较高的专家知识，或者依赖外部资源的使用。

基于深度学习的方法使算法从传统机器学习人工提取特征的方式转变为自主学习文本深层次特征的方式，避免特征工程造成的人工浪费，并且神经网络具有能在图形处理器上并行快速计算的优点，近年来取得极大进展，目前已成为情绪分类研究工作的主流方法。由于自然语言具有序列输入且不定长的特性，可以使用循环神经网络（Recurrent Neural Network, RNN）这类神经元节点序列连接的神经网络，而 LSTM 及门控循环单元（Gate Recurrent Unit, GRU）改进了 RNN 梯度消失的问题，使用 LSTM 或 GRU 编码输入文本已成为主流方法。

针对标注语料不足的问题，部分研究采用远距离监督的方式获取推特文本的情绪标签：Abdul-Mageed 等人^[36]利用 hashtag 信息对语料进行远监督标注，使用 GRU 对文本



进行细粒度的情绪多分类任务;Matsumoto 等人^[37]利用 emoji 表情符号远监督标注语料,分别实验 Bi-LSTM、Bi-GRU、卷积神经网络 (Convolutional Neural Networks, CNN) 三种神经网络的分类效果,实验结果表明该任务使用 Bi-LSTM 及 Bi-GRU 效果优于 CNN。上述研究虽然使用远监督标注方式解决了人工标注语料费时费力,且标注数据不足的问题,但是将情绪分类看作普通的多分类问题,未考虑真实用户生成文本中的情绪分类应为多标签分类问题。

2.2.2 多标签情绪分类任务

Quan 等人^[21]于 2010 年建立了 Ren-CECps 中文博客情绪分析数据集,是现有最早且应用最广泛的数据集,可以用于多标签情绪分类任务。Yang 等人^[38]使用众包的方式,利用表情图像符号、标点符号和一个小型情绪词典来标记多标签情绪分类数据集。NLPCC-2014 会议^[39]与 SemEval-2018 竞赛^[22]相继发布了中文微博及英文推特的多标签情绪分类数据集。随着该任务相关数据集的公开,吸引了越来越多研究者的关注,情绪分类任务逐渐由多分类问题转变为多标签分类问题。

(1) 一阶方法与二阶方法

多标签情绪分类任务早期仍使用基于词典或规则的方法:Sykora 等人^[40]在词和短语两个层级上构造了情绪实体词典,对推特文本进行规范化后计算每条推特的各类情绪负荷分数。

由于该任务的提出时间较一般的情绪分类任务更晚,随着机器学习算法的发展,大量工作使用了机器学习的方法,弥补了基于词典或规则的方法人工成本高且更新困难的问题:Almeida 等人^[41]将 BR、CC、LP、MLKNN 等多标签文本分类任务的方法直接用于多标签情绪分类,传统的多标签分类方法存在未考虑标签关联的问题或计算复杂的问题。Zhu 等人^[42]提出了语料库融合的方法,利用两个情绪语料库,根据语料库内约束和语料库外约束优化预测结果。Li 等人^[43]统计了 Ren-CECps 数据集同一句子中标签共现频率及上下文出现相同标签的频率,通过依赖因子图 (Dependence Factor Graph, DFG) 模型建模情绪标签及上下文之间的相关性。Zhang 等人^[44]采用 Ekman 的六类情绪分类方式在开源语料上自行标注了带有账号社交信息的多标签情绪分类数据集,使用情绪标签关联和社交关联构建因子图模型。Zhou 等人^[45]引入伪标签作为阈值,构造排序-SVM 在新闻文本上进行情绪标签排序任务,通过皮尔森相关系数作为标签关联性约束项捕捉情绪标签间的二阶关联。

神经网络具有自动捕捉文本特征的优点,随着研究者们对神经网络算法的不断革新,近年来基于深度学习的方法被大量使用。Jabreel 等人^[46]将多标签分类问题转化为由同一个分类模型解决的二分类问题,即拼接文本和标签,形成文本标签对集合,使用标签嵌入作为查询向量计算每个词的注意力,利用 Bi-GRU 进行联合编码。



与情绪的多分类任务类似,许多研究者围绕多标签情绪分类任务标注数据不足的问题进行研究,除了远监督标注的方式之外,主要使用迁移学习或多任务学习框架,通过情感分类任务辅助学习多标签情绪分类任务:

Baziotis 等人^[47]对情感分类模型进行迁移解决多标签情绪分类任务,预处理阶段进行分词和规范化,利用了词嵌入和情绪嵌入方法,分类阶段将多标签分类问题转化为多个二分类问题,获得了 2018 年 SemEval 竞赛任务 1E-c 的第一名。Yu 等人^[48]通过迁移学习,利用情感分类任务提升标注样本较少的多标签情绪分类任务的效果,编码端使用 Bi-LSTM 将文本编码至两个特征空间,分别为共享空间及情绪分类任务专有空间,通过双向注意力正交优化,捕获情感词及情绪专有词的信息,最后将两个空间输出的隐藏向量拼接传入多层感知机,使用 softmax 处理后的概率值进行多分类,需要人工设定阈值获取多个标签作为最后的分类结果,而如何找到良好的阈值函数本就是具有挑战性的问题。

Kumar 等人^[49]使用多任务框架对情感分类和多标签情绪分类任务进行联合学习,通过词级和句子级的双层注意力神经网络编码文本信息,词级注意力模块利用同义词辞典 (Distributional Thesaurus) 加入与该词语义相近的四个词的词向量以改善文本表达,最终情绪分类任务的输出层同样使用多个二分类节点处理多标签问题。这些研究虽然可以解决缺少标注数据的问题,但均为一阶关联模型,损失了标签与标签之间的共现相关性这一信息。

(2) 高阶方法

在最新研究工作使用的深度学习方法中,模型均通过序列结构捕捉共现情绪标签间的高阶关联,使实验效果获得了进一步的提升:

Huang 等人^[50]为避免序列生成结构的暴露偏差 (Exposure Bias) 现象,对序列到序列模型进行了改进,解码端使用 Bi-LSTM 构造的潜变量链考虑标签间的隐藏关联,通过信号控制的方式,将多标签情绪分类问题转化为序列的多个二分类问题,同时引入了 DeepMoji 模块利用 emoji 表情符号增强文本的特征表达。Fei 等人^[51]提出了潜在情绪记忆网络,潜在情绪模块通过使用变分自编码器 (Variational Auto-Encoder, VAE) 重构输入学习情绪分布,记忆模块捕捉对应情绪相关的特征,考虑了句中的先验情绪分布来获取情绪相关的上下文信息,最后使用 Bi-LSTM 捕捉标签间关联,实现多个标签的序列二分类,如图 2.4 所示。


图 2.4 潜在情绪记忆网络分类器结构图^[51]

Figure 2.4 Structure of latent emotion memory network classifier

2.3 现有工作的问题

针对多标签情绪分类任务的特点，仔细研究并分析相关工作后，发现了以下两个问题：

(1) 一段文本表达的多种情绪通常具有相关性。现有的部分多标签情绪分类方法未考虑情绪标签之间的共现相关性，或是考虑不足仅建模了二阶关联。目前仅有少量工作考虑了标签之间的高阶关联，这部分工作在利用注意力机制，捕捉文本中对该任务贡献更大的特征时，倾向于关注文本中相近的位置，仅能生成语义相似的多个情绪标签。造成该问题的原因一是数据集中一段文本对应多个相似情绪的样例占比较大，二是序列生成结构容易产生相同或相似的标签。模型忽视多个语义差别较大的情绪标签在文本中的位置差异，将导致文本其他部分的语义信息丢失，从而影响该任务的分类效果。

(2) 现有工作主要使用序列结构捕捉情绪标签间的高阶关联，需要标签间的顺序关系，然而现有数据集中文本的情绪标签在标注时并不遵循一定的顺序规则，即便使用启发式方法进行排序会提升一定的分类效果，但是无法保证获取了最优排序，错误排序引起的错误惩罚将影响训练过程。在近年工作中，部分方法使用固定标签顺序的多个二分类器避免了错误惩罚问题，然而固定序列不同于动态生成标签的序列，不同标签在解码阶段存在相对位置的远近差异，使模型无法准确学习到标签间的依赖关系。

因此，本文针对上述两个问题进行改进，具体方法如下：

(1) 本文采用序列到序列模型编码共现情绪标签间的相关性，通过解码端的序列生成结构捕捉情绪标签的高阶关联，利用注意力机制关注对情绪分类任务贡献度较大的文本特征，并且使用 **mask** 机制作为硬约束避免相同的标签被重复生成，同时引入注意力惩罚项作为软约束，使解码端能够学习到更多情绪标签在句中不同位置出现的信息。



(2) 本文将多个情绪标签看作集合而非序列，进一步提出一种基于强化学习的序列到集合模型，利用强化学习的延迟回报机制将序列生成问题转化为集合生成问题，避免序列生成问题的训练过程计算交叉熵损失带来的错误惩罚；利用采样及 Self-critical^[52]方法减弱 Teacher-forcing 带来的暴露偏差；同时设计奖励机制，使奖励函数更适用于多标签情绪分类任务。

2.4 本章小结

本章对现有的多标签情绪分类任务的国内外相关工作进行了梳理与总结，介绍了解决多标签分类问题、情绪分类问题的各种方法，详细介绍了多标签情绪分类使用的机器学习及深度学习方法，并对这些方法中的模型与算法进行了简要分析，最后对现有工作中的不足进行了归纳，提出了本文的两个改进点。



第3章 引入注意力惩罚项的多标签情绪分类方法

本章方法使用序列到序列模型捕捉情绪标签相关性，针对多个情绪标签的对应表达通常出现在文本中不同位置的特点，提出了引入注意力惩罚项这一改进点，从而扩大注意力分布的差异性。本章工作在 Ren-CECps 中文博客数据集及 SemEval-2018 英文推特数据集上进行了验证，实验结果表明取得了新的进展。

3.1 多标签情绪分类任务特点

在多标签情绪分类任务中，一个文本样例上共现的情绪对应的词或短语，在情绪标签间语义无关甚至相反的情况下，通常出现在文本中不同位置且间隔较远，例如 Ren-CEC 数据集中：“我们这代人如何去创造历史，不是前几辈人可以设定的，我们要与时俱进，我们要与世界接轨，我们要彰显我们这一代人的特色，我们正走在建功立业的起跑线上，凭什么就敢断言我们是如何如何的一代？”这一博客句子的标签为“expect”和“anger”，“expect”这一情绪主要分布在句子的前 3/4 部分，如“与时俱进”，“起跑线”等词，而“anger”这一情绪分布在句子的最后一个子句中，如“凭什么”，“断言”等词。

心理学家 Plutchik 提出的八类基础情绪轮图^[53]，也被称为情绪花瓣图，如图 3.1 所示，其中颜色的深浅代表该情绪的程度。

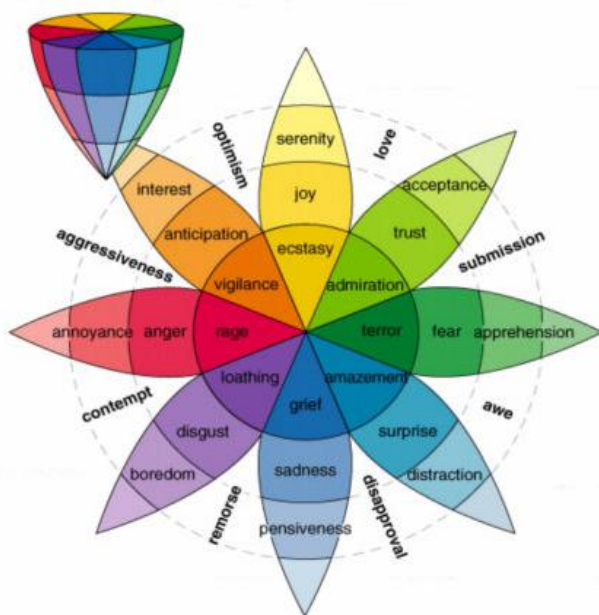


图 3.1 Plutchik 八类情绪轮图^[53]

Figure3.1 Plutchik's eight classes of emotion wheel



图上弧距离较远的情绪在触发事件或情绪原因上呈现出迥异的特点，通常不会在文本的相近位置出现，两两相对的情绪呈现出相反的特点，如紫色花瓣和与其相对的黄绿色花瓣中，颜色最深的分别为厌恶和钦佩，二者互为相反的情绪，相反的情绪在文本中共现时，则通常出现在文本的较远位置。

3.2 模型的提出及思想

神经网络方法无需人工构造特征，具有自主学习文本的隐藏语义特征这一优点。由于多标签情绪分类任务输入为文本，词与词之间存在先后顺序，任务输出为多个可能存在的关联的标签，可以使用序列结构生成，本文采用序列到序列模型作为基础的神经网络结构并加以改进，以获得更好的语义编码及标签间的高阶关联。

序列到序列模型最初被开发并用于机器翻译^[54-55]任务，假设原始语言句子包含 n 个词，目标语言句子包含 m 个词，如图 3.2 所示，该模型由编码器和解码器构成，编码器将输入句子 $X=\{x_1, x_2, \dots, x_n\}$ 转化为一定长度的隐藏向量，获取该句子的语义向量 C ；解码器根据这个中间状态按序列输出句子 $Y=\{y_1, y_2, \dots, y_m\}$ 。




图 3.2 序列到序列模型结构图

Figure3.2 Structure of sequence to sequence model

多标签情绪分类任务作为特殊的多标签分类任务，继承了多个标签之间存在关联的特点。序列到序列模型具有编码-解码的结构，现有的多标签文本分类研究表明，序列到序列模型的解码端可以对序列依赖关系建模，先生成的标签会对之后生成的标签造成影响，可以建模多个标签间的高阶关联。

文本生成任务的现有研究表明，序列生成模型在解码阶段，相近时刻捕捉的文本信息相似，倾向于生成同样的标签。在现有的部分工作中，通过 mask 机制将已经生成的标签概率值设为极小解决该问题，但这类硬约束不能解决解码端每一时刻的注意力仍关注编码端相近位置的问题，损失文本其他部分的语义信息，多个分类器仅容易得到语义相似的多个情绪标签，导致数据集中多个情绪标签语义相差较大的样例分类效果不佳。

因此，本章提出一种引入注意力惩罚项的序列到序列模型。该模型受多标签文本分类任务的研究启发，使用序列到序列模型捕捉情绪标签之间的关联性，使用双向



LSTM^[14] (Bi-LSTM) 编码文本特征；然后加以注意力机制，关注文本中对情绪标签有较大贡献的部分；最后，根据编码端的信息，解码端使用 LSTM 解码得到对应的多个标签。同时，根据多标签情绪分类任务的特点，本章引入了注意力惩罚项来关注文本中不同位置出现的情绪信息。该模型的整体框架如图 3.3 所示，下一节将对该模型进行详细介绍。

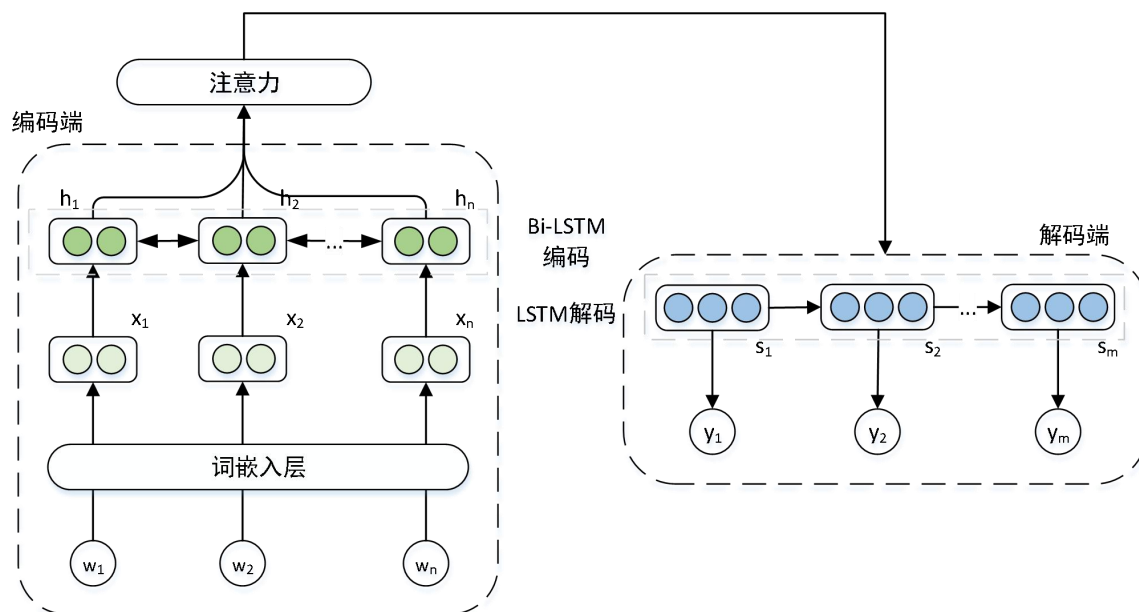


图 3.3 引入注意力惩罚项的多标签情绪分类模型框架

Figure 3.3 Structure of multi-label emotion classification model with attention penalty term

3.3 引入注意力惩罚项的序列到序列模型

本章提出了一种引入注意力惩罚项的序列到序列模型解决多标签情绪分类任务，在解码端生成情绪标签序列，将多标签分类问题转化为序列生成问题，输入为句子，输出为情绪标签，目标为最大化在模型参数 θ 下，真实标签序列 $y=\{y_1, y_2, \dots, y_m\}$ 的条件似然，即公式 (3-1)：

$$p(y|x) = \prod_{i=1}^n p(y_i | y_1, y_2, \dots, y_{i-1}, x) \quad (3-1)$$

引入注意力惩罚项可以使解码端每个时刻的注意力关注句中不同位置，获取共现却出现位置不同的情绪标签的重要特征。该模型主要由四个模块构成，分别为：词嵌入模块，Bi-LSTM 编码模块，注意力模块，LSTM 解码模块。

词嵌入模块将句子中的词转化为词向量用于后续计算，然后在编码端利用 Bi-LSTM 得到与上下文有关的隐藏表达，通过注意力机制筛选出对任务更为重要的信息，最后在解码端利用 LSTM 进行分类，每个时刻得到一个情绪标签，在识别结束符</s>后结束序列生成过程。



3.3.1 词嵌入模块

自然语言并不能直接被计算机所理解，需要转化为数字形式进行计算。词嵌入方法将高维的向量空间嵌入至一个低维空间，从而避免独热（One-Hot）编码带来的数据稀疏问题，方便模型计算，并可以通过向量之间的夹角余弦值计算词之间的相似度，还可以进行多个向量的类比推理，例如： $V(\text{国王}) - V(\text{女王}) \approx V(\text{男人}) - V(\text{女人})$ 。现有主流的词嵌入方法包括 word2vec^[56-57]、GloVe^[58]、fasttext^[59]、ELMo^[60]等。

词嵌入模块将词转化为稠密向量，使用预训练的词向量初始化文本样例中的词，未在词表中的词（Out of Vocabulary, OOV）则随机初始化，在模型训练的过程中，词向量可以作为模型参数进行微调，也可以作为固定值不参与反向传播。

在本模块中，输入待分类的句子 $[w_1, w_2, \dots, w_n]$ ， w_i 代表一个句子中第 i 个词， n 表示该句子的总词数，根据 w_i 的索引找到对应的词向量 x_i ，其中 $x_i \in \mathbb{R}^e$ ， e 为词向量的维度。经过词嵌入后，该句子可表示为 $[x_1, x_2, \dots, x_n]$ 。

3.3.2 编码模块

传统的前馈神经网络（Feed Forward Network）将文本中的每个词视作一个独立的节点，忽略了词的上下文信息，不利于文本的准确表征。循环神经网络可以通过循环结构有效传递句中词的序列信息，但RNN在长期依赖中存在梯度消失和梯度爆炸的问题，为避免这一问题，本文使用RNN的变体LSTM对输入文本进行编码。

LSTM每个单元被称为细胞（Cell），如图3.4所示，在RNN的基础上增加了细胞状态 C_t 及候选细胞状态 \tilde{C}_t ，通过门控（Gate）结构控制信息的传递，包括输入门 i_t 、遗忘门 f_t 、输出门 o_t 。输入门决定在细胞状态中存储哪些来自候选细胞的新信息，遗忘门决定从前一时刻的细胞状态中丢弃哪些信息，输出门最终决定从细胞中输出哪些信息到隐藏状态，具体计算公式为（3-2）-（3-7）：

$$i_t = \sigma(W_i[x_t, h_{t-1}] + b_i) \quad (3-2)$$

$$f_t = \sigma(W_f[x_t, h_{t-1}] + b_f) \quad (3-3)$$

$$\tilde{C}_t = \tanh(W_c[x_t, h_{t-1}] + b_c) \quad (3-4)$$

$$C_t = i_t \circ \tilde{C}_t + f_t \circ C_{t-1} \quad (3-5)$$

$$o_t = \sigma(W_o[x_t, h_{t-1}] + b_o) \quad (3-6)$$

$$h_t = o_t \circ \tanh(C_t) \quad (3-7)$$

式中 W_* 均为需要学习的参数矩阵； b_* 均为偏置项； \circ 表示哈达玛积（Hadamard product），即矩阵逐元素相乘（Element-wise Product）； $[]$ 表示向量的拼接操作。



2018223040136

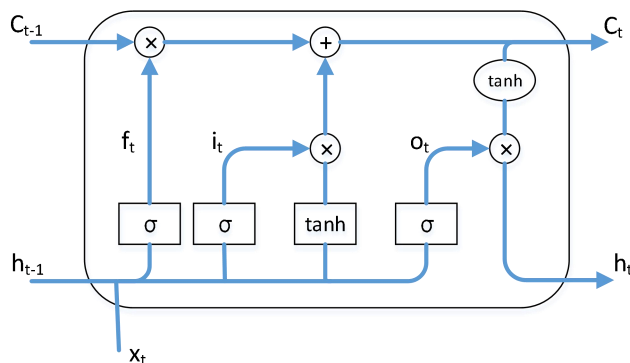


图 3.4 LSTM 结构图

Figure3.4 Structure of LSTM

单向的 LSTM 仅能编码前文信息，存在文本特征编码不充分的缺陷。Bi-LSTM 为双向的 LSTM 神经网络，如图 3.5 所示，由前向（Forward）及后向（Backward）LSTM 组合构成，可以编码文本的前文信息和后文信息，同时捕捉了上下文的依赖关系，拼接双向的隐藏状态将得到最终的文本表达 h_t 。




图 3.5 Bi-LSTM 结构图

Figure3.5 Structure of Bi-LSTM

本章工作使用 Bi-LSTM 编码文本特征，如式 (3-8)-(3-10) 所示，每个方向的 LSTM 输入均为词嵌入模块得到的词向量 x_i 和该方向前一个词的隐藏状态 h_{i-1} ，最终第 i 个词的隐藏表达为双向隐藏状态的拼接。

$$\vec{h}_i = LSTM(\vec{h}_{i-1}, x_i) \quad (3-8)$$

$$\overleftarrow{h}_i = LSTM(\overleftarrow{h}_{i-1}, x_i) \quad (3-9)$$

$$h_i = [\vec{h}_i; \overleftarrow{h}_i] \quad (3-10)$$



3.3.3 注意力模块

注意力是模仿人类观看图片时认知注意力的技术，通过注意力焦点抑制无用信息，更快获取所需信息。注意力机制在计算机视觉（Computer Vision, CV）与 NLP 领域中均得到了广泛应用^[61]。注意力的计算可以被看作成一个寻址（Addressing）过程，计算查询向量（Query）与键（Key）的相似度作为权重附加在候选值（Value）上，得到最终的 Attention Value，即包含注意力信息的表达。在 NLP 任务中，Key 和 Value 通常为同一值。

注意力机制可以增强输入端的重要部分，减弱贡献较低的部分，使神经网络更关注有效数据，同时增加模型的可解释性。在一般的序列到序列模型中，存在单一中间向量信息不足及长期依赖减弱的问题，影响解码过程的准确程度，而注意力机制通过在每个时刻产生不同的语义向量，可以很好地解决上述问题。

由于文本中只有少量词表达情绪相关的含义，本模型通过点积注意力分配权重，关注对于识别不同情绪贡献程度更高的词，同时避免 RNN 带来的损失长距离信息的问题，使序列到序列模型不受编码端只获得单一隐藏表达的限制。注意力相关的参数矩阵可以通过梯度下降法进行学习。

$$e_{t-1,i} = h_i \tanh(W_a s_{t-1}) \quad (3-11)$$

$$\alpha_{t-1,i} = \frac{\exp(e_{t-1,i})}{\sum_{j=1}^n \exp(e_{t-1,j})} \quad (3-12)$$

$$c_{t-1} = \sum_{i=1}^n \alpha_{t-1,i} h_i \quad (3-13)$$

注意力的计算过程如图 3.6 所示，根据公式（3-11）-（3-13），首先由解码端上一时刻隐藏状态 s_{t-1} 作为查询向量，与编码端每个词的隐藏表达 h_i 计算交互信息得到中间值 $e_{t-1,i}$ ，对 $e_{t-1,i}$ 进行 softmax 运算后得到注意力 $a_{t-1,i}$ ，最后使用注意力对编码端每个词的隐藏表达加权求和得到整体表达 c_{t-1} ，公式中 W_a 为需要学习的参数矩阵。




图 3.6 注意力模块

Figure3.6 Attention module



3.3.4 解码模块

解码模块即在序列到序列模型中的解码端使用 LSTM 解码得到多个标签（LSTM 的详细说明已在 3.2.2 小节给出，此处不再重复介绍），每个时刻的输入为前一时刻的隐藏状态 s_t 及标签词嵌入向量 $e(y_{t-1})$ 与编码端表达 c_{t-1} 的拼接，由于 $e(y_{t-1})$ 的输入，前序标签会对后序标签的生成造成影响，可以建立多个标签间的高阶关联，该模块具体结构如图 3.7 所示。

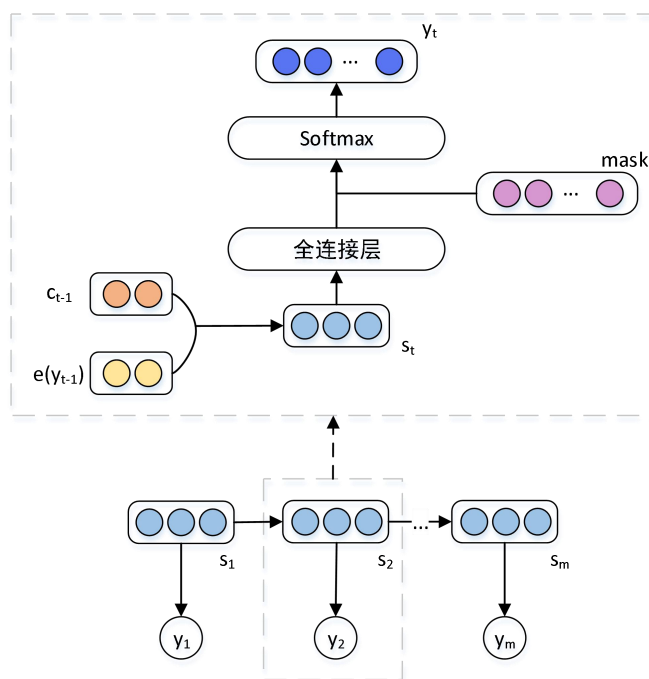


图 3.7 解码模块

Figure3.7 Decoding module

解码端初始的隐藏状态为编码端的最后状态，初始的词嵌入为起始符<s>的词嵌入，具体计算过程为公式（3-14）：

$$s_t = LSTM(s_{t-1}, [e(y_{t-1}), c_{t-1}]) \quad (3-14)$$

将每一时刻得到的隐藏状态 s_t 及编码端通过注意力加权后的整体表达 c_t 输入一个全连接层，得到每一时刻最终的隐藏状态 o_t ，通过一个线性分类器得到分类结果。每个分类器的类别均为所有情绪标签、起始符<s>和结束符</s>，**然后对所有类别的数值进行 mask 操作以防止重复生成**，经过 softmax 函数运算后归一化成相加为 1 的概率值，具体计算见公式（3-15） - （3-16）：

$$o_t = W_o f(W_d s_t + V_d c_t) \quad (3-15)$$

$$y_t = softmax(o_t + M_t) \quad (3-16)$$

式中 f 为非线性激活函数； W_o ， W_d ， V_d 均为需要学习的参数矩阵。 M_t 的取值分为两种



情况：如果该标签在前序的分类器中已经预测得出过则为负无穷 $-\infty$ ，其他情况为 0。

训练阶段使用生成标签的概率值计算损失，预测阶段使用集束搜索（Beam Search）算法。由于贪心搜索算法（Greedy Search Algorithm）仅在每一时刻选择当前状态下的最优，不能保证路径达到全局最优，集束搜索针对贪心搜索进行了改进，扩大了搜索空间，但是相比穷举搜索的指数级复杂度节约了时间和空间。集束搜索在每一时刻的分类器上选取概率最大的 k 个路径，当分类器识别到结束符 $\langle /s \rangle$ 时停止这一生成过程。

3.3.5 引入注意力惩罚项的损失函数

本模型采用的基础损失函数为交叉熵损失（Cross Entropy Loss），即公式（3-17）：

$$L_c = -\sum_{t=1}^q \hat{y}_t \log(y_t) \quad (3-17)$$

式中 q 为标签类别数； \hat{y}_t 为标注的真实值； y_t 为预测标签的概率分布。

本章工作为解决现有序列到序列模型仅捕捉文本中相近位置信息的问题，在整体损失函数中额外引入了注意力惩罚项作为约束。KL 散度（Kullback-Leibler divergence）是度量两个概率分布间差异程度的指标，可用于度量本模型解码端每两个时刻注意力分布之间的差异。但是 KL 散度具有不对称性，因此该惩罚项应为信息半径，即双向 KL 散度的平均值。通过扩大每两个时刻注意力分布的信息半径，使模型能够关注文本中不同位置蕴含的情绪信息，整体损失函数计算过程如公式（3-18）-（3-20）：

$$L_{total} = L_c - \lambda \sum_{u=0}^{t-1} \Phi(\alpha_u, \alpha_t) \quad (3-18)$$

$$\Phi(\alpha_u, \alpha_t) = \frac{1}{2} [KL(\alpha_t, \alpha_u) + KL(\alpha_u, \alpha_t)] \quad (3-19)$$

$$KL(\alpha_t, \alpha_u) = \sum_{j=1}^{d^\alpha} \alpha_{t,j} \log\left(\frac{\alpha_{t,j}}{\alpha_{u,j}}\right) \quad (3-20)$$

式中 λ 为调节惩罚项的超参数； $\alpha_{t,j}$ 为 α_t 向量的第 j 个分量； $\alpha_{u,j}$ 为 α_u 向量的第 j 个分量； d^α 为 α 的向量维度。

3.4 实验设计与分析

3.4.1 实验环境

- （1）开发平台：Linux 操作系统，NVIDIA GeForce RTX 2080 GPU，8GB。
- （2）开发工具：Python3.5.6，Anaconda（开发环境集成工具），Pycharm（IDE），Pytorch（基于 python 的深度学习框架），Sklearn（基于 Python 的机器学习框架），Numpy，



Spacy, ekphrasis 等工具。

3.4.2 实验数据

为了验证引入注意力惩罚项解决多标签分类问题的序列到序列模型的效果，本文在 Ren-CECps 数据集^[21]和 SemEval-2018^[22]数据集上进行实验。

Ren-CECps 数据集的语料为中文博客，使用细粒度的标注方式，在文档，段落，句子这三个层级上标注了情绪及情绪强度。该数据集由 1487 篇博客文章（包括新浪博客，百度博客等），11255 个段落，35096 个句子，878164 个中文单词组成，数据集包含 love、anxiety、sorrow、joy、expect、hate、anger、surprise 八类情绪。

本文面向 Ren-CECps 语料句子层面的情绪标签研究多标签情绪分类任务，句子层面的语料标注方式如图 3.8 所示。本文研究的任务为情绪分类任务，不使用情绪强度信息，在数据预处理阶段仅从 XML 文件中提取每个句子和其对应的情绪标签。中文的词与词之间没有间隔，需先进行分词处理以获取词序列，语料标注者 Ren 等人已经对句子进行了该处理，本工作将沿用该分词标准。

```
<?xml version="1.0" encoding="UTF-8" ?>
<sentence s="">或者，你就是我心里那个永远也无法用语言和文字去描述的灵魂。</sentence>
<s_no>第1段第2句标注</s_no>
<Segmented_S> /w 或者/a , /w 你/r 就/d 是/v 我心/r 里/t 那个/r 永远/d 也/d 无法/v 用/p 语言/n 和/o 文字/n 去/v 描述/v 的/u 灵魂/n . </Segmented_S>
<s_length>30</s_length>
<degree_adv start="-1" position="12" modifier_word_position="14" modifier_word_length="12" end="-1">永远</degree_adv>
<noword start="-1" position="15" modifier_word_position="24" modifier_word_length="2" end="-1">无法</noword>
<Opinion_Fact>opinion</Opinion_Fact>
<Polarity>积极</Polarity>
<Joy>0.0</Joy>
<Hate>0.0</Hate>
<Love>0.8</Love>
<Sorrow>0.0</Sorrow>
<Anxiety>0.0</Anxiety>
<Surprise>0.0</Surprise>
<Anger>0.0</Anger>
<Expect>0.0</Expect>
</sentence>
```

图 3.8 Ren-CECps 数据集样图

Figure3.8 Sample of Ren-CECps dataset

Ren-CECps 数据集整体数量较大且无标准划分，本文按照相关工作^[51]的划分方式将该数据集随机划分为训练集、验证集、测试集。

SemEval-2018 数据集的语料为英文推特，在每条推特上标注了情绪，包含 anger、anticipation、disgust、fear、joy、love、optimism、pessimism、sadness、surprise、trust 十一类。该数据集为竞赛数据集，官方划分了训练集、验证集、测试集。

表 3.1 情绪标签数量分布

Table3.1 Distribution of the number of emotion labels

每条样例情绪标签数量	句子数（Ren-CECps）	推特条数（SemEval-2018）
1	18812	1563
2	11416	4442
3	1824	3419

SemEval-2018 数据集与处理完后的 Ren-CECps 数据集的训练集标签数量分布情况



如表 3.1 所示，这两个数据集均可以用于多标签情绪分类任务，表中详细列出了包含一个标签、两个标签、三个标签的文本样例数量，两个数据集的划分情况如表 3.2 所示。

表 3.2 数据集划分

Table3.2 Datasets partition

	句子数 (Ren-CECps)	推特条数 (SemEval-2018)
训练集	24567	6838
验证集	3510	886
测试集	7019	3259

现有研究指出，出现频率较大的标签对后续分类器造成更大的影响，适当的排序可以使模型更早学会更有用的信息，从而提升模型的效果。因此，每条文本样例的情绪标签按照训练集中标签的频率，以高频标签在前低频标签在后的规则，进行了重排序。

除此之外，本文针对两个数据集中具有多个情绪标签的样例进行了分析，统计了每个样本在情绪轮图中相隔最远的两种情绪的距离，按最短弧长占整个圆的比例小于 $1/4$ 、等于 $1/4$ 和大于 $1/4$ 分类，各部分占比如图 3.9 所示。




图 3.9 数据集情绪语义距离对比图

Figure3.9 Emotion semantic distance comparison of datasets

3.4.3 文本预处理

(1) Ren-CECps 数据集

本文沿用了 Ren-CECps 语料自带的分词结果，除此之外，未对该中文博客数据集进行其他的预处理操作。

(2) SemEval-2018 数据集

SemEval-2018 的语料为英文推特文本，文本较短，存在较严重的不规范词汇和语法的使用情况，需要进行额外的文本预处理。

针对该语料，首先使用 NLTK 分词工具对语料进行简单划分，将每一条文本样例划



分为词例 (token) 序列, 英文文本中词与词之间本身存在空格作为分隔符, 分词阶段主要将词与标点符号分隔开, 再将所有词转化为其小写形式。其次, 由于推特中提及用户 “@用户” 与发布话题 “#话题” 的功能, 将 “@用户” 转化为统一的 token “<user>”, 移除 “#话题” 中的 “#” 并使用 ekphrasis 工具对话题中的组合词进行分词可以进一步改善推特文本的特征提取效果。除此之外, 本文未进行停用词和标点符号的去除, 保留了文本的语法信息。

根据 Babanejad 等人^[62]的研究, 拼写检查 (Spellcheck)、词干提取 (Stemming)、词形还原 (Lemmatization) 等文本预处理方法均能提升推特文本的情绪分析效果, 本文希望使用最少的步骤, 最简单的预处理方法将推特的不规范文本转化为规范程度更高的文本, 仅利用了拼写检查及词形还原两个方式, 通过 Spellchecker 工具和 Spacy 工具中的 en_core_web_sm 模块处理 SemEval-2018 数据集的推特文本。

3.4.4 评价指标

本文沿用相关工作^[51]的评价方式, 使用微平均 F1 (Micro-F1) 值、宏平均 F1 (Macro-F1) 值、汉明损失 (Hamming Loss, HL) 三个评价指标评价引入注意力惩罚项的多标签情绪分类方法的效果。

F 分数 (F-score) 可以整体评价精确率 (Precision, P) 和召回率 (Recall, R), 计算方式如公式 (3-21) 所示:

$$F_{\beta} = (1 + \beta^2) \frac{PR}{\beta^2 P + R} \quad (3-21)$$

β 为 1 时, F 分数即为 F1 值, 其中精确率和召回率由混淆矩阵计算得出。混淆矩阵如表 3.3 所示, TP (True Positive) 代表真正例, 即实际值为正例, 预测正确为正例的情况; FN (False Negative) 代表假负例, 即实际值为正例, 预测错误为负例的情况; FP (False Positive) 代表假正例, 即实际值为负例, 预测错误为正例的情况; TN (True Negative) 代表真负例, 即实际值为负例, 预测正确为负例的情况。

表 3.3 混淆矩阵

Table3.3 Confusion matrix

实际\预测	正例	负例
正例	TP	FN
负例	FP	TN

精确率评价预测为正例的情况中存在多少真正例, 召回率评价实际为正例的情况中存在多少真正例, 二者分别通过公式 (3-22) - (3-23) 计算:



$$P = \frac{TP}{TP + FP} \quad (3-22)$$

$$R = \frac{TP}{TP + FN} \quad (3-23)$$

$$Micro - F_1 = \frac{2PR}{P + R} \quad (3-24)$$

$$Macro - P = \frac{1}{q} \sum_{i=1}^q P^i, \quad Macro - R = \frac{1}{q} \sum_{i=1}^q R^i \quad (3-25)$$

$$Macro - F_1 = \frac{2 \times Macro - P \times Macro - R}{Macro - P + Macro - R} \quad (3-26)$$

$$Macro - F_1 = \frac{1}{q} \sum_{i=1}^q F_1^i \quad (3-27)$$

Micro-F1 值与 macro-F1 值的具体计算过程为公式 (3-24) - (3-27)，式中 q 为类别的数量。Micro-F1 值由总体样本的 P 值和 R 值计算得到，macro-F1 值有两种计算方式：一是由每个类别 P 值和 R 值求出的算术平均值计算得到，或是对每个类别的 F1 值求算术平均，本文采取后者即 (3-27) 式的方式计算 macro-F1 值。根据计算方式可知，micro-F1 值更关注样本数量多的标签，macro-F1 值更关注样本数量少的标签。

汉明距离最初用于信息论中，度量两个等长字符串的距离，即一个字符串转化为另一个字符串所需的最少替换字符个数。汉明损失可以计算两个集合汉明距离的平均值，主要用于评价多标签分类模型，具体计算公式为 (3-28)：

$$HL = \frac{1}{L} \sum_{i=1}^L \frac{y_i \Delta \hat{y}_i}{q} \quad (3-28)$$

式中 L 为样本总数； q 为标签类别数； \hat{y}_i 为真实标签集合； y_i 为预测标签集合； Δ 表示两个集合间的对称差，对称差的计算方式为求异或，即集合中对应分量相同为一，不相同为零。

3.4.5 实验设置

中文数据集使用中文维基百科语料库，通过 word2vec 工具预训练 (Pre-training) 的 300 维词向量，英文数据集使用英文维基百科 40 万词的语料库，通过 Glove 算法预训练的 300 维词向量，未在词表中出现的词则在区间 $[-0.25, 0.25]$ 上随机初始化，经过验证，初始的词向量跟随模型训练进行微调可以获得更好的效果。设置训练轮数 (epoch) 为 30，利用验证集上获得最高 micro-F1 值的模型参数再使用测试集进行测试。



使用 Bi-LSTM 编码时，样本句子的长度大多都不相同，无法直接构建张量，为提升批训练的效率，同一 batch 的编码端会以该 batch 的最长句子长度进行填充(Padding)。

模型训练时使用交叉熵损失函数和 Adam 优化器，通过余弦退火(Cosine Annealing)动态降低学习率。余弦退火通过余弦函数实现学习率衰减，即随着 epoch 的增加，学习率下降速度根据余弦值自动调整，计算方式如公式(3-29)：

$$\eta_t = \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min})(1 + \cos(\frac{T_{\text{cur}}}{T_{\max}}\pi)) \quad (3-29)$$

式中 η_{\max} 与 η_{\min} 分别为学习率的最大值和最小值； T_{cur} 与 T_{\max} 分别为 epoch 的当前值和最大值。

超参数为模型训练前人为设置的参数，表 3.4 中给出了各重要超参数的设定值，其中学习率为尚未经过余弦退火的初始设定值，全部超参数均通过验证集进行调节。

表 3.4 超参数设置

Table3.4 Settings of hyper-parameters

超参数	值	说明
η	0.0005	学习率
δ	0.6	Dropout
e	300	词向量维度
d_e	300	编码端隐藏向量维度
d_d	600	解码端隐藏向量维度
λ	0.5	惩罚项系数
β	5	集束搜索宽度
σ	64	批大小(batch size)

3.4.6 实验结果及分析

(1) 模型对比实验

为了评估引入注意力惩罚项的序列到序列多标签情绪分类方法的有效性，本文在中英文两个数据集上与近年效果最好的相关方法进行对比，包括 2018 年的 SGM 模型，RERc 模型，2020 年的 LEM 模型，具体结果如表 3.5 及表 3.6 所示，可视化结果如图 3.10 所示。针对三个方法的具体模型与算法描述如下：

SGM(2018)^[18]：首次将序列到序列模型引入多标签分类任务，编码端为 Bi-LSTM，解码端为 LSTM，解码端使用 mask 机制和全局嵌入(Global Embedding, GE)，即每个时刻的最终标签嵌入由所有标签嵌入的期望值和预测的标签嵌入组成，各部分所占比例通过超参数控制。



RERc (2018) [45]: 加入伪标签作为阈值, 构造 Rank-SVM 进行情绪标签排序任务, 使用皮尔森相关系数作为标签关联性约束项, 利用最大间隔 (Margin) 优化模型参数。

LEM (2020) [51]: 潜在情绪记忆网络, 潜在情绪模块使用变分自编码器, 通过重构输入文本的词袋来学习情绪的先验分布, 记忆模块根据潜在的情绪分布矩阵, 捕捉对应情绪相关的上下文信息, 经过多层记忆模块处理后的向量使用 Bi-GRU 在多个时刻实现多个标签的二分类。

表 3.5 Ren-CECps 数据集的实验结果对比

Table3.5 Comparison of experiment performance on Ren-CECps dataset

方法	HL(↓)	macro-F1(↑)	micro-F1(↑)
SGM(2018)	18.7%	39.2%	47.3%
RERc(2018)	20.1%	41.6%	51.1%
LEM(2020)	15.1%	44.8%	50.1%
本章方法	14.1%	45.4%	56.5%

表 3.6 SemEval-2018 数据集的实验结果对比

Table3.6 Comparison of experiment performance on SemEval-2018 dataset

方法	HL(↓)	macro-F1(↑)	micro-F1(↑)
SGM(2018)	16.5%	49.2%	61.6%
RERc(2018)	17.6%	53.9%	65.1%
LEM(2020)	14.2%	56.7%	67.5%
本章方法	13.8%	56.4%	68.1%

表 3.5 与表 3.6 中的“↑”表示该指标与效果呈正相关, 即数值越大效果越好, “↓”表示该指标与效果呈负相关, 即数值越小效果越好。



图 3.10 实验结果对比图

Figure3.10 Comparison of experiment performance

图 3.10 通过可视化方法展示了本章方法与最新方法的汉明损失、macro-F1 值和



micro-F1 值对比, 可以看出, 本章方法在各项指标上获得了较好的效果。

根据表 3.5 与表 3.6 中数据可知, 相比 2020 年的最新工作, 在中文数据集上 macro-F1 值和 micro-F1 值分别提高了 0.6% 和 6.4%, 汉明损失降低了 1%, 相比 micro-F1 值最高的 RERc 模型, micro-F1 值提高了 5.4%; 在英文数据集上, 虽然 macro-F1 值相比最新工作略有下降, 但 micro-F1 值和汉明损失均获得了更好的效果, 其中 micro-F1 值提升了 0.6%, 汉明损失降低了 0.4%。实验结果说明了引入注意力惩罚项可以更好地识别文本不同位置对应的多种情绪, 使该方法获得了比现有最新模型更好的表现, 从而证明了提出方法的有效性。

根据 3.4.2 节中图 3.9 的分析可知, 在 Ren-CECps 数据集中, 相比情绪语义近似的多标签样例, 情绪语义相差较大甚至相反的多标签样例占比更高; 而在 SemEval-2018 数据集中, 情绪语义近似的多标签样例占比更高。由于一般情况下, 语义差别越大的情绪在文本中相隔越远, 所以该方法在 Ren-CECps 数据集效果提升更加显著。

(2) 案例分析

为了验证引入注意力惩罚项作为改进的合理性, 本文进行了案例分析, 表 3.7 展示了在 SemEval-2018 数据集上“本章方法-AttnDiff”模型即不使用注意力惩罚项的序列到序列模型的错误分类样例。

表 3.7 SemEval-2018 数据集“本章方法-AttnDiff”误分类样例

Table 3.7 ‘Method of this chapter-AttnDiff’ misclassification sample on SemEval-2018 dataset

文本样例	真实标签	预测标签
#LouiseLinton - haters gonna hate keep on being your#fabulous self they'll keep on being #miserable	optimism, sadness	anger, disgust, sadness
...with the couple, so you decide to ignore everything and finish yours while dealing with the laughter and everything in the background.	joy, sadness	joy, optimism

观察表 3.7 得知, 情绪标签极性相反的情况下, 文本容易被错误分类, 如“...with the couple, so you decide.....”这一文本, 情绪标注为“joy, sadness”, 喜悦和悲伤二者语义相差较大, 在情绪轮图中的弧长占比为 3/8, 被错误分类为“joy, optimism”这两个语义相近的情绪, 二者在情绪轮图中的弧长占比为 1/16。由此可知, 忽视共现情绪在文本中位置差异的序列到序列模型, 存在容易错误生成语义近似情绪标签的问题。

如图 3.11 所示, 在 SemEval2018 测试集的总体样本中, 多个标签在情绪轮图中弧长占比小于 1/4 情绪语义相似的情况占 46%, 等于 1/4 情绪语义相差较大的情况占 16%,



大于 $1/4$ 情绪语义相反的情况占 23%。但“本章方法-AttnDiff”在该测试集上的误分类样本中，占比小于 $1/4$ 的情况占 42%，相较总样本下降了 4%，等于 $1/4$ 的情况占 22%，大于 $1/4$ 的情况占 34%，分别相较总样本上升了 6% 和 11%。由统计数据可知，在不引入注意力惩罚项的一般序列到序列模型中，解码端的多个时刻主要捕捉了文本相近位置的信息，导致情绪语义相差较大甚至相反的文本样例无法取得较好的分类效果。本章方法引入了注意力惩罚项后，标签的误分类样本情况大致与样本情况类似，由此可以证明，引入注意力惩罚项可以更好地捕捉语义差别较大的多个情绪标签对应的文本特征。




图 3.11 SemEval-2018 数据集误分类情况

Figure 3.11 Misclassification situation on SemEval-2018 dataset

3.5 本章小结

鉴于语义差别较大的多个情绪标签的对应特征通常出现在文本的不同位置，现有工作难以准确识别这类样例，本章工作利用引入注意力惩罚项的序列到序列模型解决多标签情绪分类问题。该模型通过序列结构建模情绪标签之间的共现相关性，引入注意力惩罚项捕捉多种情绪在文本中的位置差异，提升了多标签情绪分类任务的效果。实验部分在 Ren-CECps 中文博客数据集及 SemEval-2018 英文推特数据集上验证了这一方法的有效性，对比近年的相关工作均有提高，并且通过案例分析证明了改进点的合理性。



第4章 基于强化学习的多标签情绪分类方法

本章工作为解决利用序列到序列模型实现多标签情绪分类时，标签顺序问题带来的错误惩罚，提出了强化学习这一改进点，通过延迟回报机制将情绪标签视为集合而非序列。本章工作在 Ren-CECps 数据集及 SemEval-2018 数据集上进行了验证，实验结果表明取得了新的进展。

4.1 模型的提出及思想

序列到序列模型的训练阶段一般采用交叉熵或最大似然估计（Maximum Likelihood Estimation, MLE）方法计算模型损失，均需要预先确定标签的顺序。只有得到最优的标签序列，序列到序列模型在多标签分类任务上才能获得最好的效果。然而多标签情绪分类任务现有的数据集中，并不存在带有明确情绪序列标注的文本，即使情绪原本在每个文本样例中有序，但在这一分类任务中，难以评价是否找到了这一最优的序列，现有工作仅通过启发式方法对情绪标签进行重排序来达到一定的效果提升。

在标注数据集无法获得最优序列的情况下，使用序列到序列模型解决多标签情绪分类存在错误惩罚的问题，即预测结果正确但生成标签的顺序与标注标签的顺序不一致而被损失函数惩罚，如一条文本样例对应的真实标签为“anticipation, joy, optimism”，预测标签为“optimism, anticipation, joy”，虽然得到了正确的情绪标签集合，但是顺序不同仍然会导致较高的惩罚。转化多标签分类任务为序列生成任务的最新相关工作均将标签按频率从高到低进行排序，使模型学习更多高频标签的信息，从而对后续的生成过程产生更好的影响。但多标签情绪分类任务的数据集大多存在数据倾斜的情况，这种排序方式导致算法忽略低频尾标签^[63]的信息，造成尾标签的分类效果不佳。因此，多标签情绪分类任务中的情绪标签应该被当作无序集合而不是有序序列，无序集合具有交换不变性，即交换集合中的任何两个元素而不影响损失函数的计算。

在序列到序列模型的训练阶段中，解码端每一时刻的输入是上一时刻的真实值，即 Teacher-forcing 方法，该方法使模型更易收敛，加快模型的训练速度，但是导致模型缺少了一定的容错能力。在预测过程中缺少 Teacher-forcing，解码端每一时刻的输入是上一时刻概率最高的预测值，在某一时刻出现的误差会沿着顺序结构一直向后传播，导致误差越来越大，产生暴露偏差问题。

现有避免错误惩罚和暴露偏差问题的工作为：使用 Bi-LSTM 将解码端设置为固定标签序列的二分类器，但这种方式同样存在不合理之处，多个标签固定顺序时，存在固定序列中各个标签在解码阶段相对位置（即距离）存在差异的问题，使模型受到干扰，



难以准确学习到标签间的依赖程度。而强化学习的延迟回报机制可以避免一般的损失计算方法带来的错误惩罚问题，还可以避免固定序列带来的标签依赖程度差异问题，并且采样方法可以减弱序列到序列模型的暴露偏差现象。

传统的交叉熵损失函数与评价指标体系并不统一，导致训练阶段和测试阶段的目的不同，影响模型效果的评价。强化学习在优化策略时，可以选取特定的指标（如 F1 值）作为回报，避免损失函数的设置与最终评价指标评估的效果相差过大。序列生成情绪标签可以被看作为寻找最优路径的过程，模型预测时一般使用贪婪搜索算法获得标签序列，强化学习在计算梯度时使用的 Self-critical 方法^[52]将贪婪搜索算法作为基准，可以使训练和测试阶段的表现更具有一致性。

基于强化学习的方法具有可以将多个标签视为无序集合，训练阶段和测试阶段更贴合的这两个优点，本章工作将利用强化学习方法，用序列到集合的模型解决多标签情绪分类问题。该模型的大体框架与前文相似，下一节将介绍本文使用的强化学习方法，4.3 节将对该模型与强化学习方法的各个要素进行详细介绍。

4.2 强化学习方法

强化学习（Reinforcement Learning, RL）是机器学习的三种基本模式之一，近年来，成为热门的计算方式，在游戏及图像领域广泛应用，如 AlphaGo 等。在 NLP 领域，强化学习也在自动对话^[64]和推荐系统^[65]中发挥着重要的作用。

4.2.1 强化学习

强化学习是在探索与试错中获得更高奖励的过程，如图 4.1 所示，智能体（Agent）在与环境（Environment）的交互中进行学习，根据策略（Policy）采取动作（Action）转换环境的状态（State）来获得回报（Reward），以上过程也可以被称作为一个马尔可夫决策过程（Markov Decision Process, MDP）。上述要素的具体定义如下：智能体是学习器；环境是除智能体之外，与智能体交互的所有事物；动作是智能体的行为；状态是智能体从环境获取的信息；回报是环境针对动作给予的反馈；策略则是从环境状态到动作的映射，定义了智能体在某个时刻的行为方式。




图 4.1 强化学习过程示意图

Figure 4.1 Reinforcement learning process



马尔可夫决策过程同马尔可夫链一样具有马尔可夫性质，状态转移概率仅取决于当前的状态，即每个状态仅取决于前一刻的状态，与时间序列中更早的状态无关。马尔可夫决策过程的状态不仅与前一刻的状态有关，还和动作有关。该过程可以被表示为一个四元组 $\{S, A, P_{s,a}, R\}$ ，其中 S 为环境的状态空间， A 为智能体的动作空间， $P_{s,a}$ 为 t 时刻状态 s 下的动作 a 导致 $t+1$ 时刻产生状态 s' 的概率， R 为回报。

4.2.2 策略梯度

本文使用的强化学习算法为策略梯度（Policy Gradients），该方法的优化目标为最大化累计回报的期望 $E(R|\pi_\theta)$ ，使用梯度下降或梯度上升法学习参数化的策略 π ，属于基于策略（Policy-based）的学习。

策略参数的更新过程如公式（4-1）所示：

$$\theta \leftarrow \theta + \eta g \quad (4-1)$$

式中 θ 为参数； η 为学习率； g 为策略梯度。

假设一个马尔可夫决策过程的状态、动作和奖励的序列轨迹为 $\mathcal{L} = (s_0, a_0, r_1, \dots, s_{m-1}, a_{m-1}, r_m, s_m)$ ，策略梯度可以表示为公式（4-2）：

$$g = R \nabla_\theta \sum_{t=0}^m \log \pi(a_t | s_t; \theta) \quad (4-2)$$

R 与该轨迹的出现概率呈正相关，即 R 越大时，该轨迹出现的概率越高，反之出现概率越低，公式的导数部分使策略朝梯度最大的方向进行更新。

基于策略的方法可以学习随机的策略，随机策略允许智能体在采样时不总是采取概率值最大的动作，从而探索更多空间，减弱了探索-利用困境（Exploration-Exploitation Dilemma），这一特点使基于策略的方法具有更好的收敛性。策略梯度遵循梯度寻找最佳参数，可以使结果收敛于最值，且使用梯度下降法更符合神经网络参数的调优方式，更新过程可见，更具有可解释性。

策略梯度算法不限于有无模型的分类方式，可以作为通用的优化算法使用，现有工作已经证明了序列到序列模型解决多标签分类任务的优势，有模型的方法可以利用该领域知识，所以本文使用有模型的策略梯度算法。

4.3 基于强化学习的序列到集合模型

本文提出的基于强化学习的序列到集合模型主要由两个部分组成，即主要模型和引入强化学习的要素设计，其中主要模型采用本文上一章提出的序列到序列模型，同样由四个主要模块构成，即：词嵌入模块，Bi-LSTM 编码模块，注意力模块，LSTM 解码模块。本节不再进行重复说明。



由于现有数据集未对情绪标签排序的问题，本节工作引入强化学习实现多标签情绪分类。强化学习的各部分设计如下：智能体为模型的解码器，环境状态为解码器当前时刻的状态 s_t ，智能体的动作即预测当前标签 y_t ，策略为根据状态 s_t 产生动作 y_t 的条件概率，可以表示为参数化的网络。

优化策略的目标函数为期望回报值，为便于通过梯度下降法计算，可以最小化负的期望回报值，回报设置为 F1 值，具体计算方式如公式（4-3） - （4-4）：

$$L(\theta) = -E_{y \sim p_\theta} [r(y)] \quad (4-3)$$

$$r(y) = F_1(y, y^*) \quad (4-4)$$

由于回报函数不可微，需要利用蒙特卡罗（Monte-Carlo）思想采样得到梯度的近似值，而蒙特卡罗采样方式具有较大的随机性，影响采样序列，导致回报存在较大的方差。本文通过 self-critical 方法解决这一问题，self-critical 方法在梯度估计上增加基准（Baseline）的约束，基准通常是之前回报的平均值或者贪心搜索算法获得的回报，本文将使用贪心搜索算法的回报作为基准，推导过程见公式（4-5） - （4-7）：

$$\nabla_\theta L(\theta) = -E_{y \sim p_\theta} [r(y) \nabla_\theta \log p_\theta(y)] \quad (4-5)$$

$$\nabla_\theta L(\theta) \approx -r(y) \nabla_\theta \log p_\theta(y) \quad (4-6)$$

$$\nabla_\theta L(\theta) \approx -[r(y^s) - r(y^g)] \nabla_\theta \log(p_\theta(y^s)) \quad (4-7)$$

如图 4.2 所示， y^s 是从概率分布 p_θ 中采样得到的标签序列， y^g 是利用贪心搜索算法生成的标签序列。Self-critical 方法不仅可以降低梯度估计的方差，贪心搜索这一基准还可以增加模型训练和测试阶段生成标签模式的一致性从而减弱暴露偏差。




图 4.2 Self-critical 结构图

Figure4.2 Structure of Self-critical



4.4 实验设计与分析

4.4.1 实验环境

- (1) 开发平台: Linux 操作系统, NVIDIA GeForce RTX 2080Ti GPU, 8GB。
- (2) 开发工具: Python3.5.6, Anaconda, Pycharm, Pytorch, Sklearn, Numpy, Spacy, ekphrasis 等。

4.4.2 实验数据

为了验证基于强化学习的序列到序列模型解决多标签情绪分类问题的效果,本章工作仍选择在 Ren-CECps 中文博客数据集及 SemEval-2018 英文推特数据集上进行实验,两个数据集的划分方式同 3.4.2 节, Ren-CECps 数据集的文本粒度仍为句子级, SemEval-2018 数据集文本的预处理方式同 3.4.3 节。

两个训练集中标签分布情况如表 4.1 和表 4.2 所示,数据集均存在倾斜问题。Ren-CECps 的训练集中 love 为数量最多的标签, surprise 为数量最少的标签, 大约为 10 倍的数量级关系; SemEval-2018 的训练集中 disgust 为数量最多的标签, 大约是数量最少的 trust 标签的 7.5 倍。为证明本章方法对情绪标签序列不敏感, 实验使用的数据集未对标签进行排序。

表 4.1 Ren-CECps 训练集标签分布情况

Table4.1 Distribution of labels in Ren-CECps train set

标签	love	anxiety	sorrow	joy	expect	hate	anger	surprise
出现次数	11908	10096	8183	6223	4633	3533	2236	1120

表 4.2 SemEval-2018 训练集标签分布情况

Table4.2 Distribution of labels in SemEval-2018 train set

标签	disgust	anger	joy	sadness	optimism	fear
出现次数	2602	2544	2477	2008	1984	1242
标签	anticipation	pessimism	love	surprise	trust	
出现次数	978	795	700	361	357	

4.4.3 评价指标

本文沿用上一章的评价指标, 使用 micro-F1 值、macro-F1 值、汉明损失评价基于强化学习的多标签情绪分类方法的效果。本文在 3.4.4 节详细介绍了这些评价指标及其计算方式, 在此不再赘述。



4.4.4 实验设置

由于强化学习的探索过程慢且不确定性高，难以收敛至最优值，消耗大量计算资源，所以模型参数先通过一般的序列到序列模型进行预训练，将预训练阶段在验证集上得到 micro-F1 值最高的模型参数作为后续强化学习训练过程的初始值，加快模型收敛速度。经实验发现，回报设置为 micro-F1 值能够比 macro-F1 值获得更好的效果，所以本文使用 micro-F1 值作为回报。

本节实验的词嵌入预训练语料及方式，优化器和学习率衰减设置同 3.4.5 节。词嵌入阶段，中文数据集使用中文维基百科语料库通过 word2vec 预训练得到的 300 维词向量，英文数据集使用英文维基百科语料库通过 Glove 预训练得到的 300 维词向量。未在词表中出现的词则在区间 $[-0.25, 0.25]$ 上随机初始化，初始的词向量跟随模型训练进行微调。模型训练时使用 Adam 优化器，通过余弦退火动态降低学习率。表 4.3 中的超参数为强化学习阶段的超参数。

表 4.3 超参数设置

Table 4.3 Settings of hyper-parameters

超参数	值	说明
η	0.0001	学习率
δ	0.5	Dropout
e	300	词向量维度
d_e	300	编码端隐藏向量维度
d_d	600	解码端隐藏向量维度
σ	64	Batch size

4.4.5 实验结果及分析

(1) 模型对比实验

为了评估基于强化学习的序列到集合多标签情绪分类模型的有效性，本文在中英文两个数据集上与多个基准模型和最新方法进行了对比，包括：Bi-LSTM-BR 模型，TextCNN-BR 模型，Bi-LSTM-JB 模型，TextCNN-JB 模型，2018 年的 SGM 模型及 RERc 模型，2020 年的 LEM 模型。

BR 为二元关联法，JB (Joint Binary) 表示引入了标签关联性，Bi-LSTM 与 TextCNN^[66]均是可用于 NLP 任务的常见神经网络模型，三种最新方法已在 3.4.6 节中进行了详细介绍。本文针对不同方法的分类效果进行了观察与分析，同一模型的 JB 方法均能获得比传统 BR 方法更好的分类效果，证明了引入共现标签间的关联对多标签情绪分类任务的有效性，具体结果如表 4.4 及表 4.5 所示，可视化结果如图 4.3 所示。



表 4.4 Ren-CECps 数据集的实验结果对比

Table4.4 Comparison of experiment performance on Ren-CECps dataset

方法	HL(↓)	macro-F1(↑)	micro-F1(↑)
Bi-LSTM-BR	21.2%	27.7%	29.0%
TextCNN-BR	20.4%	30.1%	32.2%
Bi-LSTM-JB	17.4%	31.1%	37.4%
TextCNN-JB	16.0%	38.4%	41.3%
SGM(2018)	18.7%	39.2%	47.3%
RERc(2018)	20.1%	41.6%	51.1%
LEM(2020)	15.1%	44.8%	50.1%
本文第一部分工作	14.1%	45.4%	56.5%
本章方法	16.4%	49.8%	56.9%

表 4.5 SemEval-2018 数据集的实验结果对比

Table4.5 Comparison of experiment performance on SemEval-2018 dataset

方法	HL(↓)	macro-F1(↑)	micro-F1(↑)
Bi-LSTM-BR	24.5%	43.7%	49.8%
TextCNN-BR	19.8%	46.5%	54.8%
Bi-LSTM-JB	18.3%	48.5%	60.8%
TextCNN-JB	16.1%	49.6%	61.2%
SGM(2018)	16.5%	49.2%	61.6%
RERc(2018)	17.6%	53.9%	65.1%
LEM(2020)	14.2%	56.7%	67.5%
本文第一部分工作	13.8%	56.4%	68.1%
本章方法	13.8%	57.2%	68.3%

表 4.4 与表 4.5 中的“↑”表示该指标与效果呈正相关，“↓”表示该指标与效果呈负相关。

由图 4.3 的可视化展示可知，本章方法在各项指标上取得了较好的效果。由表 4.4 与表 4.5 中数据可知，在 Ren-CECps 数据集上，相比 2020 年的最新工作虽然汉明损失略微上升，但其他指标均有显著提升，macro-F1 值和 micro-F1 值分别提高了 5%和 6.8%，相比 micro-F1 值最高的 RERc 模型，micro-F1 值提高了 5.8%，相比本文第一部分工作，macro-F1 值和 micro-F1 值进一步提高了 4.4%和 0.4%；在 SemEval-2018 数据集上，相比 2020 年的最新工作，汉明损失降低了 0.4%，macro-F1 值和 micro-F1 值分别提高了 0.5%和 0.8%，相比本文第一部分工作，macro-F1 值和 micro-F1 值进一步提高了 0.8%



和 0.2%。实验结果说明了基于强化学习的多标签情绪分类方法比现有最新模型的分类效果更好，证明了本章方法的有效性。



图 4.3 实验结果对比图

Figure4.3 Comparison of experiment performances

在现有工作使用的序列到序列模型中，识别到结束符</s>时直接停止标签的序列生成过程，从而控制标签数量；而本文使用的强化学习方法通过采样实现探索过程，可能生成更多的情绪标签，导致汉明损失这一指标效果不佳。但相较第一部分工作，两个数据集上 macro-F1 值的提升可以证明该方法的合理性，强化学习方法的引入避免了通过频率高低对情绪标签排序，使模型能更好地学习到低频尾标签的样本特征。由表 4.1 及表 4.2 对两个数据集标签对应样本数的统计结果可以看出，Ren-CECps 数据集的数据倾斜情况较 SemEval-2018 数据集更为严重，所以效果提升也更加显著。

(2) 消融实验

为了验证模型中强化学习模块的作用，本节在 Ren-CECps 与 SemEval-2018 两个数据集上设置了消融实验，结果如表 4.6 与表 4.7 所示，其中“本章方法-RL”表示仅使用不引入强化学习采样与损失函数的方法，但根据情绪标签在数据集中的出现频率对标签进行排序，“本章方法-sort-RL”表示不对数据集中的标签排序，且不使用强化学习方法。

表 4.6 Ren-CECps 数据集针对排序和强化学习的消融实验结果

Table4.6 Ablation experiment for sorting and reinforcement learning on Ren-CECps dataset

方法	HL(↓)	macro-F1(↑)	micro-F1(↑)
本章方法-sort-RL	16.1%	42.5%	54.8%
本章方法-RL	14.5%	44.2%	55.6%
本章方法	16.4%	49.8%	56.9%



表 4.7 SemEval-2018 数据集针对排序和强化学习的消融实验结果

Table 4.7 Ablation experiment for sorting and reinforcement learning on SemEval-2018 dataset

方法	HL(↓)	macro-F1(↑)	micro-F1(↑)
本章方法-sort-RL	14.7%	54.3%	66.5%
本章方法-RL	14.4%	55.9%	67.2%
本章方法	13.8%	57.2%	68.3%

从表 4.6 与表 4.7 中可以得出, 虽然使用启发式方法对标签进行排序可以一定程度地提升模型的效果, 相较未进行排序操作的方法, 在中文数据集上 macro-F1 值和 micro-F1 值分别提高了 1.7% 和 1.8%, 汉明损失降低了 1.6%, 在英文数据集上 macro-F1 值和 micro-F1 值分别提高了 1.6% 和 0.7%, 汉明损失降低了 0.3%。但引入强化学习后, 本章提出的方法对比有排序操作的序列到序列模型, 在中文数据集上 macro-F1 值和 micro-F1 值分别提高了 5.6% 和 1.3%, 在英文数据集上 macro-F1 值和 micro-F1 值分别提高了 1.3% 和 1.1%, 汉明损失降低了 0.6%。

在两个数据集上, macro-F1 值的提高相较 micro-F1 值都更加明显, 说明了该方法对低频尾标签的分类效果提升较为显著, 证明了强化学习这一改进点的有效性, 也说明了集合生成方式比序列生成方式更适用于多标签情绪分类任务。

4.5 本章小结

现有工作的序列到序列模型能够很好地捕捉标签间关联, 但多个情绪标签的最优顺序难以获取, 训练阶段预测标签与真实标签顺序不同导致错误惩罚, 固定标签序列虽然避免错误惩罚但会存在依赖强度差异的问题。针对上述问题, 本章提出了基于强化学习的序列到集合多标签情绪分类模型。该模型通过延迟回报机制将序列生成问题转化为集合生成问题, 提升了多标签情绪分类任务的效果。实验部分同样在 Ren-CECps 数据集及 SemEval-2018 数据集上验证了这一方法的效果, 对比近年的相关工作及本文第一部分工作均有提高, 并且通过消融实验证明了改进点的有效性。



2018223040136



第5章 总结与展望

5.1 工作总结

情绪分析在网络快速发展的当下已然成为自然语言处理领域中的重要任务之一。社交媒体上大量用户生成的文本中包含情绪信息,由于一段文本在多数情况下会表达不止一种情绪,且多种情绪通常存在关联,多标签情绪分类任务应运而生,该任务也能为多种自然语言处理任务提供支持。

本文首先阐述了多标签情绪分类任务的重要意义,然后按照该任务的发展历程对相关工作进行了归纳和总结,不仅包括一般的多标签文本分类方法和早期的情绪分类方法,更详细介绍了近年的多标签情绪分类方法。鉴于深度学习相较基于规则和机器学习的方法更有优势,现有分类效果较好的模型也均使用深度学习方法,本文同样使用深度学习方法进行该任务的研究工作。

序列到序列模型最初用于机器翻译任务,近年来通过将多标签分类问题转化为序列生成问题的方式用于多标签文本分类任务,然而该模型的运用仍存在不足之处,并且社交媒体上用户生成的带有情绪的文本具有特殊性,不能直接将其他多标签分类任务的模型套用于多标签情绪分类任务上。在详细分析相关工作之后,本文根据现有方法的不足,提出了以下两个改进点及创新点:

(1) 提出了一种引入注意力惩罚项的多标签情绪分类方法。

目前用于多标签情绪分类任务的部分深度学习方法丢失了情绪标签间的共现相关信息,其他领域的多标签分类研究工作已经表明使用序列到序列模型可以有效捕捉多个标签之间的关联。但使用序列生成结构获取多个情绪标签时,难以识别在文本中间隔较远,语义差别较大的多种情绪。因此,在编码文本的语义信息和捕捉多种情绪之间的相关性时应该关注文本中不同位置的情绪相关特征。本文在序列到序列模型的基础上引入了注意力惩罚项作为软约束,从而更好地捕捉文本不同位置的情绪表达。

(2) 提出了一种基于深度强化学习的多标签情绪分类方法。

使用序列到序列模型解决多标签情绪分类任务的方法,会因为标注者或研究者的错误排序导致训练过程存在错误惩罚现象,现有工作避免这一问题的方法为:将解码端的序列多分类器改为固定序列的多个二分类器,但固定序列仍存在标签间距离差异导致的依赖程度差异问题。因此,通过集合生成方式产生文本的多个情绪标签更适用于该任务。本文在序列到序列模型的基础上引入了强化学习方法,将模型解码器视为智能体,使用延迟回报机制避免标签顺序带来的错误惩罚问题,同时避



免了固定序列存在的标签间相关程度差异问题。

为验证以上两个改进点的有效性，本文设置了一系列与现有最新工作的对比实验和消融实验。对比其他工作，本文的两个模型在 Ren-CECps 中文博客数据集与 SemEval-2018 英文推特数据集上均有提升。验证基于深度强化学习的多标签情绪分类模型时，本文设置了去除强化学习并对数据集标签排序的序列到序列模型作为消融实验的对比项，证明了引入强化学习方法的有效性。

5.2 研究展望

本文分析了多标签情绪分类现有工作的不足，提出了两种改进方案，在序列到序列模型中引入注意力惩罚项和强化学习，实验证明两种方法的效果对比现有工作均有提升。但在本文基础上，未来还可以开展进一步的深入研究：

（1）针对社交媒体上用户生成文本长度较短，语法不规范，存在许多错词、新词，并且文本中存在 emoji 表情和字符表情等一系列特殊性，应加强编码端对文本信息的提取和去噪能力，如编码前对文本进行更多的规范化处理，使用 Transformer 模型作为编码器，或增加专门针对 emoji 表情和字符表情的词嵌入模块。

（2）在强化学习过程中，存在一定的探索-利用困境，即利用回报更高的动作还是探索新动作。由于多标签情绪分类任务的数据集中部分情绪标签对应的样本较少，存在数据倾斜问题，可以通过抖动策略等方式使模型学习到更多尾标签样本的信息，进一步提升 macro-F1 值。



参考文献

- [1] 中国互联网络信息中心. 第 47 次中国互联网络发展状况统计报告[R/OL].(2021-02-03) [2021-03-25].<http://www.cnnic.net.cn/hlwfzyj/hlwxxzbj/hlwtjbg/202102/P020210203334633480104.pdf>
- [2] Liu Z, Liu L. Public Emotion Monitoring and Surveillance in Emergencies[J]. Systems Engineering, 2010, 7.
- [3] Qian Y, Zhang Y, Ma X, et al. EARS: Emotion-aware recommender system based on hybrid information fusion[J]. Information Fusion, 2019, 46: 141-146.
- [4] Dong Y, Chen H, Qian W, et al. Micro-blog social moods and Chinese stock market: The influence of emotional valence and arousal on Shanghai Composite Index volume[J]. International Journal of Embedded Systems, 2015, 7(2): 148-155.
- [5] Desmet B, Hoste V. Emotion detection in suicide notes[J]. Expert Systems with Applications, 2013, 40(16):6351-6358.
- [6] 杨开漠, 吴明芬, 陈涛. 广义文本情感分析综述[J]. 计算机应用, 2019, 039(02):6-14.
- [7] 赵泽青. 网络评论观点挖掘综述[J]. 现代计算机(专业版),2019(07):49-53.
- [8] Ekman P, Friesen W V, O'sullivan M, et al. Universals and cultural differences in the judgments of facial expressions of emotion[J]. Journal of personality and social psychology, 1987, 53(4): 712.
- [9] Strapparava C, Mihalcea R. Semeval-2007 task 14: Affective text[C]//Proceedings of the Fourth International Workshop on Semantic Evaluations (SemEval-2007). 2007: 70-74.
- [10] Frijda N H. The emotions[M]. Cambridge University Press, 1986.
- [11] Plutchik R. A general psychoevolutionary theory of emotion[M]//Theories of emotion. Academic press, 1980: 3-33.
- [12] Hochreiter S, Schmidhuber J, et al. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735-1780.
- [13] Boutell M R, Luo J, Shen X, et al. Learning multi-label scene classification[J]. Pattern recognition, 2004, 37(9): 1757-1771.
- [14] Fürnkranz J, Hüllermeier E, Mencía E L, et al. Multilabel classification via calibrated label ranking[J]. Machine learning, 2008, 73(2): 133-153.
- [15] Ghamrawi N, McCallum A. Collective multi-label classification[C]//Proceedings of the 14th ACM international conference on Information and knowledge management. 2005: 195-200.
- [16] Read J, Pfahringer B, Holmes G, et al. Classifier chains for multi-label classification[J]. Machine learning, 2011, 85(3): 333.
- [17] Tsoumakas G, Katakis I, Vlahavas I. Random k-labelsets for multilabel classification[J]. IEEE transactions on knowledge and data engineering, 2010, 23(7): 1079-1089.
- [18] Yang P, Sun X, Li W, et al. SGM: sequence generation model for multi-label classification[C]//COLING, 2018: 3915-3926.
- [19] Quan C, Ren F. Sentence emotion analysis and recognition based on emotion words using Ren-CECps[J]. International Journal of Advanced Intelligence, 2010, 2(1): 105-117.
- [20] Mohammad S, Bravo-Marquez F, Salameh M, et al. Semeval-2018 task 1: Affect in tweets[C]//Proceedings of the 12th international workshop on semantic evaluation. 2018: 1-17.



2018223040136

- [21] Zhang M L, Zhou Z H. ML-KNN: A lazy learning approach to multi-label learning[J]. Pattern recognition, 2007, 40(7): 2038-2048.
- [22] Clare A, King R D. Knowledge discovery in multi-label phenotype data[C]//European conference on principles of data mining and knowledge discovery. 2001: 42-53.
- [23] Elisseeff A, Weston J. A kernel method for multi-labelled classification[C]//Advances in Neural Information Processing Systems 14(NIPS). 2001, 14: 681-687.
- [24] Zhang M L, Zhou Z H. A review on multi-label learning algorithms[J]. IEEE transactions on knowledge and data engineering, 2013, 26(8): 1819-1837.
- [25] Mohammad S F. The NRC emotion intensity lexicon[DB/OL]. (2020-03-15)[2021-03-25]. <https://saifmohammad.com/WebPages/AffectIntensity.htm>
- [26] Strapparava C, Mihalcea R. Learning to identify emotions in text[C]//Proceedings of the 2008 ACM symposium on Applied computing. 2008: 1556-1560.
- [27] Strapparava C, Valitutti A. WordNet-Affect: an affective extension of WordNet[C]//Proceedings of the International Conference on Language Resources and Evaluation (LREC). 2004, 4(1083-1086): 40.
- [28] Shen Y, Li S, Zheng L, et al. Emotion mining research on micro-blog[C]//Proceedings of 2009 1st IEEE Symposium on Web Society. 2009:71-75.
- [29] Balahur A, Hermida J M, Montoyo A. Detecting implicit expressions of sentiment in text based on commonsense knowledge[C]//Proceedings of the 2nd Workshop on Computational Approaches to Subjectivity and Sentiment Analysis (WASSA 2011). 2011: 53-60.
- [30] Roberts K, Roach M A, Johnson J, et al. EmpaTweet: Annotating and Detecting Emotions on Twitter[C]//Proceedings of the Eight International Conference on Language Resources and Evaluation (LREC). 2012, 12: 3806-3813.
- [31] Balabantaray R C, Mohammad M, Sharma N. Multi-class twitter emotion classification: A new approach[J]. International Journal of Applied Information Systems, 2012, 4(1): 48-53.
- [32] Princeton University. WordNet: A lexical database for English[DB/OL]. (2005-11-15)[2021-03-25]. <https://wordnet.princeton.edu/>
- [33] Suttles J, Ide N. Distant supervision for emotion classification with discrete binary values[C]//International Conference on Intelligent Text Processing and Computational Linguistics. 2013: 121-136.
- [34] Quan X, Wang Q, Zhang Y, et al. Latent discriminative models for social emotion detection with emotional dependency[J]. ACM Transactions on Information Systems (TOIS), 2015, 34(1): 1-19.
- [35] Agrawal A, An A. Unsupervised emotion detection from text using semantic and syntactic relations[C]//2012 IEEE/WIC/ACM International Conferences on Web Intelligence and Intelligent Agent Technology. 2012, 1: 346-353.
- [36] Abdul-Mageed M, Ungar L. Emonet: Fine-grained emotion detection with gated recurrent neural networks[C]//Proceedings of the 55th annual meeting of the association for computational linguistics. 2017: 718-728.
- [37] Matsumoto K, Yoshida M, Kita K. Classification of Emoji Categories from Tweet Based on Deep Neural Networks[C]//Proceedings of the 2nd International Conference on Natural Language Processing and Information Retrieval. 2018: 17-25.
- [38] Yang J, Jiang L, Wang C, et al. Multi-label emotion classification for tweets in weibo: method and application[C]//2014 IEEE 26th International Conference on Tools with Artificial Intelligence. 2014: 424-428.



-
- [39] China Computer Federation. The 3rd CCF Conference on Natural Language Processing & Chinese Computing[EB/OL]. (2014-12-23)[2021-03-25]. <http://tcci.ccf.org.cn/conference/2014/index.html>
 - [40] Sykora M D, Jackson T, O'Brien A, et al. Emotive ontology: Extracting fine-grained emotions from terse, informal messages[J]. IADIS International Journal on Computer Science and Information Systems. 2013,8(2): 106-118.
 - [41] Almeida A M G, Cerri R, Paraiso E C, et al. Applying multi-label techniques in emotion identification of short texts[J]. Neurocomputing, 2018, 320: 35-46.
 - [42] Zhu S, Li S, Chen Y, et al. Corpus fusion for emotion classification[C]//Proceedings of COLING 2016, the 26th International Conference on Computational Linguistics: Technical Papers. 2016: 3287-3297.
 - [43] Li S, Huang L, Wang R, et al. Sentence-level Emotion Classification with Label and Context Dependence[C]//Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing. 2015: 1045-1053.
 - [44] Zhang X, Li W, Lu S. Emotion detection in online social network based on multi-label learning[C]//International Conference on Database Systems for Advanced Applications. 2017: 659-674.
 - [45] Zhou D, Yang Y, He Y. Relevant emotion ranking from text constrained with emotion relationships[C]//Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1. 2018: 561-571.
 - [46] Jabreel M, Moreno A. A deep learning-based approach for multi-label emotion classification in tweets[J]. Applied Sciences, 2019, 9(6): 1123.
 - [47] Baziotis C, Nikolaos A, Chronopoulou A, et al. NTUA-SLP at SemEval-2018 Task 1: Predicting Affective Content in Tweets with Deep Attentive RNNs and Transfer Learning[C]//Proceedings of The 12th International Workshop on Semantic Evaluation. 2018: 245-255.
 - [48] Yu J, Marujo L, Jiang J, et al. Improving Multi-label Emotion Classification via Sentiment Classification with Dual Attention Transfer Network[C]//Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing. 2018: 1097-1102.
 - [49] Kumar A, Ekbal A, Kawahra D, et al. Emotion helps Sentiment: A Multi-task Model for Sentiment and Emotion Analysis[C]//The 2019 International Joint Conference on Neural Networks (IJCNN). 2019: 1-8.
 - [50] Huang C, Trabelsi A, Qin X, et al. Seq2emo for multi-label emotion classification based on latent variable chains transformation[J]. arXiv preprint arXiv:1911.02147, 2019.
 - [51] Fei H, Zhang Y, Ren Y, et al. Latent emotion memory for multi-label emotion classification[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2020, 34(5): 7692-7699.
 - [52] Rennie S J, Marcheret E, Mroueh Y, et al. Self-critical sequence training for image captioning[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 7008-7024.
 - [53] Plutchik R. Emotions: A general psychoevolutionary theory[J]. Approaches to emotion, 1984: 197-219.
 - [54] Cho K, van Merriënboer B, Gülçehre Ç, et al. Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation[C]//Proceedings of The 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2014.



2018223040136

- [55] Sutskever I, Vinyals O, Le Q V. Sequence to sequence learning with neural networks[J]. arXiv preprint arXiv:1409.3215, 2014.
- [56] Mikolov T, Chen K, Corrado G, et al. Efficient Estimation of Word Representations in Vector Space[J]. Computer Science, 2013.
- [57] Mikolov T, Sutskever I, Chen K, et al. Distributed representations of words and phrases and their compositionality[J]. arXiv preprint arXiv:1310.4546, 2013.
- [58] Pennington J, Socher R, Manning C D. Glove: Global vectors for word representation[C]//Proceedings of The 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2014: 1532-1543.
- [59] Joulin A, Grave É, Bojanowski P, et al. Bag of Tricks for Efficient Text Classification[C]//Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics: Volume 2, Short Papers. 2017: 427-431.
- [60] Peters M, Neumann M, Iyyer M, et al. Deep Contextualized Word Representations[C]//Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1. 2018: 2227-2237.
- [61] 朱张莉, 饶元, 吴渊, 等. 注意力机制在深度学习中的研究进展[J]. 中文信息学报, 2019, 33(6): 1-11.
- [62] Babanejad N, Agrawal A, An A, et al. A comprehensive analysis of preprocessing for word representation learning in affective tasks[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. 2020: 5799-5810.
- [63] Bhatia K, Jain H, Kar P, et al. Sparse local embeddings for extreme multi-label classification[C]//Proceedings of the 28th International Conference on Neural Information Processing Systems-Volume 1. 2015: 730-738.
- [64] Li X, Chen Y N, Li L, et al. End-to-End Task-Completion Neural Dialogue Systems[C]//Proceedings of the Eighth International Joint Conference on Natural Language Processing. 2017: 733-743.
- [65] Wang X, Chen Y, Yang J, et al. A reinforcement learning framework for explainable recommendation[C]//2018 IEEE international conference on data mining (ICDM). 2018: 587-596.
- [66] Kim Y. Convolutional neural networks for sentence classification[J]. arXiv preprint arXiv:1408.5882, 2014.



攻读学位期间取得的研究成果

[1]吴妍秀.基于神经网络的多标签情绪分类研究[J].现代计算机,2021,27(7):51-54.



2018223040116



致 谢

日月如梭，文籍如海，探讨不及，朱黄敢怠。三年的研究生生涯将要画上最终的句号，有喜悦，有不舍，万般思绪涌上心间，在此，我要向帮助我、支持我的所有人表达由衷的谢意！

首先，感谢我的导师于中华老师。2017年10月，在获得推免资格后，第一次走近了实验室，向于老师了解自然语言处理这一研究方向。于老师治学严谨，对待学术研究认真负责，对待教育工作始终保持热情，给予我们无微不至的指导。每周举行的讨论班，加快了我的学习进度，拓宽了我的思维与视野，使我的科研以及工程能力都得到了提高，令我受益匪浅。祝愿于老师身体健康，工作顺利！

感谢实验室的陈黎老师，为人亲切，平时会对我们的项目进行指导，关心我们的实验进度与毕业论文写作进度，在我遇到困难时鼓励我勇往直前。在我担任陈老师计算机网络课程的助教时，深刻体会老师授课细致用心，对待教学工作认真负责，对助教也关照有加。祝愿陈老师家庭美满，万事如意！

感谢实验室的师兄师姐们，感谢陈珊珊，彭楚越，刘露，艾鑫，姚攀，王艺霖，李艳斌，对我科研和项目的指导以及日常生活的帮助。感谢实验室的同届小伙伴，感谢徐杨，高跃，易红，臧义，一起讨论文，一起探讨项目，一起讨论代码问题，一起奋斗，一起成长。感谢实验室的师弟师妹们，感谢卢永美，卜令梅，李好，蒲金垚，陶嘉鸿，在和你们的讨论交流中，同样收获了很多。三年的科研道路，感谢你们的陪伴，使我在前行的过程中更有力量。

感谢我的室友们，在平时生活中互相关心，在论文撰写的过程中互相鼓励。

感谢我的家人、男朋友和朋友们，在我迷茫时给予我引导，在我疲惫时给予我安慰，在我困难时给予我帮助。你们的鼓励和支持是我坚实的后盾，激励我不忘初心，砥砺前行，对生活和未来充满信心。

感谢各位专家老师，对我的论文和答辩提出宝贵意见和建议，使我能发现并改进自己的不足之处。

最后，感谢我的母校四川大学。岷峨挺秀，锦水含章；巍巍学府，德渥群芳。从本科时期的江安校区，到研究生时期的望江校区，不知不觉已度过人生中的七年时间，感谢川大提供了优越的学习环境和丰富的教学资源，我为有幸成为川大人而自豪，源自内心和生命的深处。

言尽于此，愿诸君之勿忘也。临颖神驰，书不成字，纸短情长，伏惟珍重。



2018223040116